

Anexo A. Integración GEIH–ECV, exposición tecnológica y mercado laboral en Colombia

Emparejamiento transversal, pseudo-panel, estimaciones y escenarios 2026–2030

Investigación: IA y Crecimiento Económico

2026-09-29

Tabla de contenidos

1. Introducción y objetivos	1
2. Integración de datos, exposición tecnológica y pseudo-panel	2
2.1. Emparejamiento de cortes transversales GEIH–ECV	2
2.1.1. Fundamento teórico y supuestos	2
2.1.2. Universos, armonización y reglas de transferencia	3
2.1.3. Distancia, selección del donante y coherencia del hogar	3
2.1.4. Resultados de la integración transversal	5
2.1.5. Evaluación posterior: coherencia y límites	6
2.2. Construcción y asignación de los índices de exposición	11
2.2.1. Fundamentos y elección de indicadores	11
2.2.2. Correspondencias ocupacionales y asignación individual	12
2.2.3. Normalización fija y sensibilidad de escala	13
2.2.4. Cobertura y muestra comparable	14
2.2.5. Del índice individual a la exposición agregada	15
2.3. Construcción y evaluación del pseudo-panel	16
2.3.1. Teoría, definición de cohortes y agregación	16
2.3.2. Resultados de construcción y evaluación	18
3. Estimaciones econométricas clásicas	19
3.1. Diseño común, bases y criterio de interpretación	19
3.2. Diferencias en diferencias con exposición continua	19
3.2.1. Marco teórico, ecuación y base	19
3.2.2. Resultados estáticos e interpretación	20
3.2.3. Dinámica temporal y sensibilidad de asignación ocupacional	21

3.3. Triple diferencia y habilitación	22
3.3.1. Marco teórico, ecuación y base	22
3.3.2. Resultados e interpretación	22
3.4. Exposición territorial tipo shift-share	25
3.4.1. Marco teórico, ecuación y base	25
3.4.2. Resultados e interpretación	25
3.5. Efectos fijos de cohorte y primeras diferencias	26
3.5.1. Marco teórico, ecuaciones y bases	26
3.5.2. Resultados e interpretación	27
3.6. Sensibilidad de escala y trazabilidad	29
4. Aprendizaje automático: DML y R-learner	30
4.1. Fundamento, bases y organización de la evaluación	30
4.2. DML/PLR: ecuación, resultados y diagnóstico	30
4.3. R-learner: heterogeneidad y evaluación externa	31
5. Escenarios condicionales para 2026–2030	32
5.1. Marco de proyección, fuentes y supuestos	32
5.2. Microsimulación salarial con AIOE	33
5.2.1. Ecuaciones y base	33
5.2.2. Resultados e interpretación económica	33
5.3. Escenarios departamentales de desempleo, no cotización e ingreso	34
5.3.1. Ecuaciones y bases	34
5.3.2. Resultados principales AIOE	35
5.3.3. Comparación con Webb-IA y LLM	35
5.4. Indicadores ilustrativos y límites del ejercicio	36
6. Síntesis, limitaciones y reproducción	36
6.1. Procedimiento de reproducción	36
6.2. Código técnico de construcción de exposición	37
Referencias	38

1. Introducción y objetivos

El análisis de la inteligencia artificial y la automatización en el mercado laboral colombiano requiere relacionar ocupaciones e ingresos con educación, acceso tecnológico y condiciones de vida. La GEIH aporta información laboral detallada, mientras que la ECV permite caracterizar dimensiones complementarias del bienestar. El objetivo es integrar sus cortes transversales de 2022–2025, construir un pseudo-panel de cohortes y utilizar ambas bases para estudiar las asociaciones entre exposición tecnológica, desempleo, no cotización pensional e ingreso laboral. La GEIH donante reúne septiembre–noviembre (SON) y la ECV receptora es anual; se

transfieren atributos entre personas comparables, sin enlazar identidades ni seguir longitudinalmente a las mismas personas.

La investigación se organiza en tres etapas. Primero, el emparejamiento estadístico combina atributos de ambas encuestas mediante covariables comunes y reglas explícitas de coherencia. Segundo, los registros integrados se agrupan por departamento, sexo y generación de nacimiento para formar cohortes observables durante cuatro años. Tercero, los microdatos y las medias de cohortes se utilizan en modelos econométricos, procedimientos de aprendizaje automático y escenarios prospectivos. D’Orazio et al. (2006) y Ridder & Moffitt (2007) fundamentan la combinación de fuentes; Deaton (1985) y Verbeek (2008) proporcionan el marco del pseudo-panel.

La exposición principal se mide con AIOE, desarrollado por Felten et al. (2021). Se contrasta, en regresiones separadas, con la exposición a IA basada en patentes de Webb (2020) y con la exposición a modelos de lenguaje de Eloundou et al. (2024). Los indicadores de software y robots de Webb amplían el análisis a otras formas de automatización. Se utiliza la variante de calificación GPT-4 denominada `dv_rating_beta` para LLM; el origen de los datos y su publicación se distinguen del periodo colombiano analizado. Cada indicador mide susceptibilidad de tareas u ocupaciones, no adopción efectiva, probabilidad de desempleo ni una pérdida de puestos de trabajo ya observada.

La estrategia conserva AIOE como índice de referencia para **los tres resultados laborales**: desempleo, no cotización pensional e ingreso. Webb–IA y LLM se estiman en regresiones separadas sobre muestras comparables, en lugar de combinarse en un único indicador, porque este diseño permite identificar qué canal tecnológico concreto está asociado a un resultado, sin que quede oculto dentro de un índice compuesto; software y robots se incorporan como extensiones del mismo ejercicio. La envolvente máxima, que resume los tres índices principales en un solo valor, no sustituye a los indicadores específicos: se calcula únicamente como ejercicio de sensibilidad. Esta elección de AIOE como referencia responde al objeto de investigación definido desde el diseño del estudio, no a una selección posterior del índice que arroje el signo o la significancia más favorables.

La reproducibilidad numérica, la validez descriptiva de la integración y la identificación econométrica son dimensiones distintas. La coincidencia de cálculos no prueba independencia condicional ni causalidad. Por ello, las regresiones se interpretan como asociaciones condicionadas a su diseño y los ejercicios 2026–2030 como escenarios sujetos a supuestos. Los códigos de procesamiento, emparejamiento, construcción de índices, estimación y proyección están disponibles en el repositorio público de la investigación para facilitar su reproducción y trazabilidad.

2. Integración de datos, exposición tecnológica y pseudo-panel

Este capítulo describe cómo se construye la base de datos que sustenta el resto del documento. Primero se presenta el emparejamiento estadístico entre la GEIH y la ECV: su fundamento teórico, las reglas de armonización y transferencia entre encuestas, el criterio de distancia utilizado para asignar donantes y los resultados de esa integración, incluida su evaluación de coherencia y sus límites. Segundo, se explica la construcción de los índices de exposición tecnológica, AIOE, Webb–IA, LLM, software y robots: su fundamento, la forma en que se asignan a las ocupaciones colombianas, su normalización en escala fija, la muestra común exigida para compararlos y el procedimiento para agregarlos a nivel departamental y de cohorte. Tercero, se describe el pseudo-panel: la definición de cohortes por departamento, sexo y generación aproximada de nacimiento, el cálculo de sus medias y los resultados de su construcción y evaluación. En conjunto, estas tres secciones documentan el origen de los datos y de las variables de exposición que se utilizan en las estimaciones econométricas presentadas más adelante.

2.1. Emparejamiento de cortes transversales GEIH–ECV

Esta sección detalla el emparejamiento estadístico entre GEIH y ECV. Presenta primero su fundamento teórico y el supuesto de independencia condicional que lo sustenta; luego describe los universos, la armonización de variables y las reglas de transferencia entre encuestas; a continuación explica el criterio de distancia utilizado para seleccionar al donante y la forma en que se preserva la coherencia dentro del hogar; después reporta

los resultados numéricos de la integración; y finalmente evalúa su coherencia interna y sus límites mediante contrastes distributivos y validación laboral retrospectiva.

2.1.1. Fundamento teórico y supuestos

El emparejamiento estadístico reconstruye una base conjunta cuando dos fuentes observan grupos distintos de variables y comparten un conjunto de covariables. Sean L los atributos laborales de GEIH, B los atributos de bienestar de ECV y C las características comunes. Rässler (2002) y D’Orazio et al. (2006) explican que conocer las distribuciones marginales condicionadas no determina, por sí solo, la relación entre L y B . El supuesto de independencia condicional permite escribir

$$f(L, B | C) = f(L | C)f(B | C).$$

Es un supuesto identificador, no un resultado demostrado por el algoritmo. Con momentos finitos implica $\text{Cov}(L, B | C) = 0$, pero covarianza nula no implica independencia. Tampoco una distancia pequeña entre vecinos acredita que el supuesto se cumpla. La ley de covarianza total muestra qué se deja sin identificar sin información conjunta adicional:

$$\text{Cov}(L, B) = E\{\text{Cov}(L, B | C)\} + \text{Cov}\{E(L | C), E(B | C)\}.$$

La integración requiere también comparabilidad de mediciones, soporte suficiente y transportabilidad de la información donante al receptor. Las diferencias entre una GEIH SON y una ECV anual pueden reflejar ventanas de referencia y estacionalidad; la selección de meses no elimina automáticamente esas diferencias. La unicidad de llaves y la ausencia de duplicados tampoco demuestran independencia estadística de entrevistas.

2.1.2. Universos, armonización y reglas de transferencia

El bloqueo, es decir, el criterio que agrupa a las personas comparables antes de buscar al donante más cercano, se define por departamento, zona y sexo: solo se compara a personas dentro del mismo bloque. Dentro de cada bloque, la edad, la educación, la jefatura del hogar, el tamaño del hogar, la pertenencia a la población en edad de trabajar (PET, desde 15 años) y la actividad principal completan la comparación fina entre donante y receptor. La educación se armoniza en cinco categorías comunes a ambas encuestas: sin educación o preescolar, primaria, secundaria o media, técnica o tecnológica, y universitaria o posgrado. En la ECV se respetan las rutas de asistentes y no asistentes escolares; en la GEIH, la Escuela Normal Superior se integra en la categoría de secundaria o media. La educación ausente se conserva como ausente y no se convierte en una categoría de “sin educación”.

Una vez integradas las dos encuestas, varias variables y resultados de interés se construyen con reglas operativas propias, no siempre equivalentes a las definiciones oficiales del DANE. La Tabla 1 resume esas definiciones para las variables y resultados usados en el resto del documento.

Tabla 1: Definiciones operativas de las variables y resultados contruidos a partir del emparejamiento GEIH-ECV

Variable o resultado	Definición operativa y alcance
Ocupación y desocupación	Indicadores OCI y DSI del donante; restringidos a PET
Actividad principal	P6240==1, utilizada en distancia; no equivale a toda la ocupación
Desempleo descriptivo	Desocupados divididos por ocupados más desocupados
No cotización pensional	P6920=2 entre ocupados con respuestas 1/2; excluye pensionados y faltantes

Variable o resultado	Definición operativa y alcance
Ingreso laboral	INGLABO; análisis logarítmico restringido a valores positivos
Pobreza e ingreso per cápita	Atributos del donante del jefe receptor, sincronizados dentro del hogar
Habilitación TIC	Uso individual de computador y acceso a internet del hogar; no mide adopción de IA

Fuente: elaboración propia.

La no cotización es una aproximación parcial a la desprotección laboral, no la clasificación oficial de informalidad del DANE. Los ausentes de pobreza se conservan; desconocido no equivale a no pobre. Si no existe un jefe único identificable, la regla de sincronización conserva valores ausentes. Los indicadores del hogar repetidos entre personas y ponderados con FEX_C describen personas que viven en esa condición, no proporciones de hogares.

2.1.3. Distancia, selección del donante y coherencia del hogar

Esta sección define cómo se mide la cercanía entre dos personas y cómo se elige al donante. Para cada persona receptora se construye un vector de seis componentes: edad y educación normalizadas por construcción entre 0 y 1, tamaño del hogar acotado entre 1 y 15 personas para evitar valores atípicos, y tres indicadores binarios (jefatura del hogar, pertenencia a la población en edad de trabajar y actividad principal de trabajar) multiplicados por pesos de diseño (2, 5 y 3, respectivamente) que los priorizan sobre las demás dimensiones. Ese vector es

$$z_i = \left(\frac{\text{edad}_i}{100}, \frac{\text{educ}_i}{4}, 2\text{jefe}_i, \frac{\max\{1, \min(\text{tamhogar}_i, 15)\}}{10}, 5\text{PET}_i, 3\mathbb{I}(\text{trabaja}_i = 1) \right).$$

Cada componente recoge una característica de la persona i , reescalada para que todas queden en un rango comparable antes de sumar sus diferencias al cuadrado. La edad se divide entre 100 sin ningún tope aplicado: existen unos pocos casos registrados de hasta 108 o 109 años en los datos integrados (entre 15 y 25 personas por año, de un total de varios cientos de miles), para quienes esta coordenada supera ligeramente el valor 1 en lugar de quedar exactamente entre 0 y 1 como las demás. Es una imprecisión conocida y no corregida en la implementación, cuyo efecto sobre la selección del donante es marginal dado lo infrecuente del caso y lo pequeño del exceso. El nivel educativo, ya armonizado en las 5 categorías descritas antes (de 0 a 4), se divide entre 4 y por construcción siempre queda entre 0 y 1, sin necesitar ningún tope adicional. El tamaño del hogar se acota entre 1 y 15 miembros mediante $\max\{1, \min(\text{tamhogar}_i, 15)\}$: primero se limita por arriba a 15 con el mínimo, y luego por abajo a 1 con el máximo, de modo que un hogar reportado con un número inusualmente alto de personas no distorsiona la distancia; el resultado se divide entre 10. Las otras tres coordenadas son indicadores binarios, que valen 1 si la condición se cumple y 0 si no: jefatura del hogar (jefe_i), pertenencia a la población en edad de trabajar (PET_i , 15 años o más; no debe confundirse con la población económicamente activa) y actividad principal de trabajar, esta última escrita como función indicadora $\mathbb{I}(\text{trabaja}_i = 1)$, que vale 1 cuando la variable de actividad principal de la encuesta (P6240) es igual a 1, y 0 en cualquier otro caso. A estos tres indicadores se les asignan pesos de diseño distintos (2, 5 y 3, respectivamente) porque, a diferencia de la edad y la educación, que ya varían de forma continua entre 0 y 1, un indicador de sí o no solo puede tomar los valores 0 o 1: sin ese peso adicional, coincidir o no en una de estas tres condiciones pesaría en la distancia lo mismo que una diferencia pequeña de edad o de nivel educativo, cuando el diseño busca precisamente privilegiar la coincidencia en población en edad de trabajar, actividad principal y jefatura del hogar por encima de la simple cercanía en las variables continuas.

Sea $\mathcal{D}(i)$ el conjunto de donantes del mismo departamento, zona y sexo que cumplen la regla de disponibilidad educativa descrita a continuación. La asignación con reemplazo es

$$j^*(i) = \arg \min_{j \in \mathcal{D}(i)} \left[\sum_{k \in K_i} (z_{ik} - z_{jk})^2 \right]^{1/2}, \quad \widehat{L}_i = L_{j^*(i)},$$

donde K_i contiene las dimensiones utilizables, $j^*(i)$ es el donante elegido para la persona receptora i (el que minimiza la distancia entre sus vectores z), y $\widehat{L}_i = L_{j^*(i)}$ transfiere en bloque a la persona receptora los atributos laborales L del donante seleccionado (L se definió en la sección anterior como los atributos laborales propios de la GEIH); el símbolo “sombrero” en $\widehat{L}_i$ indica que ese valor es imputado, no observado directamente para i . Si educación falta en el receptor, se omite esa coordenada; cuando está observada se restringe el conjunto admisible a donantes con educación disponible. Si todo el conjunto donante carece de ella, también se omite. Las demás coordenadas deben ser válidas. Los factores de la distancia son decisiones de diseño, no parámetros estimados ni restricciones infinitas.

Si el bloque no tiene donantes, se amplía la búsqueda a otros departamentos manteniendo zona y sexo; no se exige proximidad geográfica. Si tampoco existe ese conjunto, la ejecución se detiene. El orden de los candidatos interviene en los empates; por eso se conserva trazabilidad y se evalúa un vecino alternativo equidistante.

Los atributos laborales se transfieren conjuntamente desde el donante individual. Para un atributo de hogar Q y un jefe receptor único h , la regla es $\widehat{Q}_i = Q_{j^*(h)}$ para todos los miembros del hogar. La varianza intrahogar nula resultante es una restricción construida, no una validación externa.

Los ingresos se expresan a precios de octubre de 2025:

$$w_{it}^{real} = w_{it}^{nom} \frac{IPC_{2025}}{IPC_t}.$$

El IPC de referencia es observado, 151,76, con diciembre de 2018=100. La utilización de un índice de octubre para la ventana anual de cada fuente es una convención de deflación, no una corrección de estacionalidad ni composición. DANE (2025) documenta la referencia utilizada.

Tabla 2: IPC y factores monetarios utilizados en la integración.

Año	IPC	Factor a octubre de 2025
2022	123.51	1.2287
2023	136.45	1.1122
2024	143.83	1.0551
2025	151.76	1

2.1.4. Resultados de la integración transversal

Esta sección reporta los resultados numéricos de la integración GEIH-ECV descrita en los apartados anteriores. Primero se presentan las fuentes, las exclusiones territoriales y el número de registros integrados por año. Después se reportan las tasas de desempleo y no cotización ya imputadas en la base conjunta, junto con dos indicadores de calidad del emparejamiento: el porcentaje de personas para las que fue necesario ampliar la búsqueda de donante a otro departamento, y la concentración de uso de un mismo donante entre varios receptores. Estas cifras describen la base integrada completa, no las muestras más restringidas que usan las regresiones posteriores.

Tabla 3: Fuentes, exclusiones territoriales y registros integrados por año.

Año	Personas GEIH	Personas ECV	Excluidos	Receptores	Donantes
2022	222.473	251.925	1.251	250.674	78.524
2023	210.430	240.212	889	239.323	75.446

Tabla 3: Fuentes, exclusiones territoriales y registros integrados por año.

Año	Personas GEIH	Personas ECV	Excluidos	Receptores	Donantes
2024	201.792	228.688	690	227.998	73.154
2025	205.555	235.350	546	234.804	73.901

Los “excluidos” son los registros de la ECV que no cuentan con la información de departamento, zona o sexo que exige el bloqueo descrito antes, y que por lo tanto no pueden integrarse en absoluto. Los “receptores” son el número de personas de la ECV que sí quedaron integradas; esta cifra es menor que las “personas ECV” (el tamaño original de la encuesta, antes de excluir a quienes carecen de esa información territorial) y no debe confundirse con los “donantes” (el número de personas distintas de la GEIH que efectivamente prestaron su información laboral). Estas dos últimas cifras difieren porque la asignación se hace con reemplazo: un mismo donante puede ser, a la vez, el más cercano para varias personas receptoras, así que el número de donantes distintos utilizados es casi siempre menor que el número de receptores que los usan.

La siguiente tabla reporta, para cada año, las tasas de desempleo y no cotización pensional ya imputadas sobre la base integrada, junto con dos indicadores propios de la calidad del emparejamiento. “Desempleo %” y “No cotiza %” se calculan directamente sobre las personas ya integradas, ponderadas por su factor de expansión, exactamente igual que se calcularía sobre cualquier encuesta de hogares. “Ampliación %” es el porcentaje de población receptora para la que no existía ningún donante dentro de su propio bloque de departamento, zona y sexo, y que por tanto tomó su información laboral de un donante de otro departamento; en 2025 esto ocurre únicamente en la zona rural de ocho departamentos de la Orinoquía y la Amazonía (Arauca, Casanare, Putumayo, Amazonas, Guainía, Guaviare, Vaupés y Vichada), donde la GEIH no tiene suficientes hogares rurales encuestados para servir de donante local. “Usos medios” y “Usos máximos” cuentan, para cada donante de la GEIH, a cuántas personas receptoras de la ECV le prestó su información laboral ese año, y reportan el promedio y el caso más extremo de esa distribución. Por ejemplo, un donante con 5 usos fue seleccionado ese año como el más cercano para 5 personas receptoras distintas, y a todas ellas les transfirió exactamente el mismo vector de atributos laborales. Los usos medios, de alrededor de 3, indican que en promedio cada donante utilizado se repite entre unas 3 personas receptoras. Los usos máximos, en cambio, muestran el caso más extremo: un único donante cuyos atributos laborales terminan representando a decenas o incluso a más de cien personas receptoras a la vez, de modo que cualquier error o particularidad atípica de esa sola persona en la GEIH se propaga a todas las personas que comparten ese mismo donante.

Tabla 4: Tasas ponderadas imputadas y concentración de utilización de donantes.

Año	Desempleo %	No cotiza %	Ampliación %	Usos medios	Usos máximos
2022	10.00	56.47	1.25	3.2	129
2023	9.48	54.57	1.25	3.2	95
2024	8.85	54.06	1.24	3.1	113
2025	7.25	54.53	1.24	3.2	99

La siguiente tabla evalúa, antes de aplicar la ampliación de búsqueda, cuántos bloques de departamento, zona y sexo existen en cada encuesta y cuántos coinciden entre ambas. “Bloques ECV” y “Bloques GEIH” son el número de combinaciones observadas en cada fuente; “Comunes” son las que aparecen en las dos y sí tienen donante disponible sin necesidad de ampliar la búsqueda. “Sin donante local” cuenta los bloques de la ECV que no tienen ningún donante de la GEIH en su mismo bloque: en 2025 son 16 bloques, correspondientes a la zona rural de ocho departamentos de la Orinoquía y la Amazonía (Arauca, Casanare, Putumayo, Amazonas, Guainía, Guaviare, Vaupés y Vichada) para ambos sexos, donde la GEIH simplemente no encuestó suficientes hogares rurales para servir de donante. La solución no es inventar un donante ni relajar las demás condiciones: se mantiene el mismo criterio de zona y sexo, pero se busca al donante más cercano en cualquier otro departamento del país, sin exigir cercanía geográfica; esto es precisamente lo que la tabla anterior mide como “Ampliación %”. La cobertura resume qué proporción de los bloques de la ECV logra tener un donante local disponible sin necesitar esa ampliación.

Tabla 5: Soporte de bloques territoriales antes de ampliar la búsqueda.

Año	Bloques ECV	Bloques GEIH	Comunes	Sin donante local	Cobertura %
2022	130	114	114	16	87.70
2023	130	114	114	16	87.70
2024	130	114	114	16	87.70
2025	130	114	114	16	87.70

2.1.5. Evaluación posterior: coherencia y límites

Esta sección evalúa, después de realizado el emparejamiento, qué tan bien se conserva la información laboral transferida, combinando tres tipos de comprobación: consistencia contable interna, similitud de las distribuciones agregadas, y una validación laboral retrospectiva más exigente. Esta última compara, para cada persona receptora, si la ocupación imputada coincide con la que la propia ECV reporta de forma independiente para un subconjunto de personas.

La siguiente tabla resume comprobaciones contables básicas sobre la base integrada de 2023: qué tan bien coincide la condición de ocupado transferida con la que la propia ECV reporta de forma independiente, si se respetaron restricciones lógicas elementales (los menores de 15 años no deberían recibir salario ni ocupación imputados, y los desocupados oficiales no deberían recibir salario laboral) y qué tan correlacionado queda el ingreso imputado con el ingreso que la ECV ya reportaba de forma nativa para quienes lo tenían. Por ejemplo, la sensibilidad de ocupación alcanza 99,95 %: de cada 10.000 personas que la ECV reporta trabajando de forma independiente, prácticamente todas (9.995) también quedan clasificadas como ocupadas por la imputación; la concordancia ocupacional global en la PET, más exigente porque compara la categoría ocupacional completa y no solo el estatus de ocupado/no ocupado, es de 92,97 %; y ningún menor de 15 años recibe salario u ocupación imputados (0 registros en ambos casos), lo que confirma que el filtro de edad se respeta estrictamente. La calidad del código ocupacional transferido es igualmente alta: de los cientos de miles de ocupados imputados en la base integrada de 2023, solo 3 registros quedan con código CIUO ausente o de formato inválido, una incidencia prácticamente nula. La correlación entre el ingreso imputado y el ingreso que la propia ECV reporta de forma nativa para quienes ya lo tenían es de 0,274 (Pearson); este valor moderado-bajo no señala un problema del método, sino que refleja su propio diseño: el donante se elige por cercanía en el vector de características z_i (edad, educación, jefatura, tamaño del hogar, PET y actividad), no por nivel de ingreso, de modo que el emparejamiento busca transferir de forma consistente la condición laboral y ocupacional, y no reproducir el monto exacto del ingreso individual.

Tabla 6: Coherencia interna y restricciones contables, 2023.

Comprobación	Resultado
Sensibilidad de Ocupación (Trabajaba en ECV)	99.95 %
Concordancia Ocupacional Global en PET	92.97 %
Menores de 15 años con Salario Imputado	0 registros
Menores de 15 años clasificados Ocupados	0 registros
Desocupados oficiales con Salario Laboral	0 registros
Ocupados imputados con código CIUO ausente o de formato inválido	3 registros
Correlación Ingreso Imputado vs. Nativo ECV	0.274 (Pearson)

La siguiente tabla aplica, año por año, tres métricas de acierto a la reconstrucción laboral más amplia, comparando dos variantes del método: la distancia completa a seis dimensiones (6D), que sí incluye la actividad principal, y una variante de sensibilidad que la excluye (5D), para verificar qué tanto depende el resultado de esa única dimensión. La validación compara, para cada persona receptora, si la ocupación imputada coincide con la que la propia ECV reporta de forma independiente; los “verdaderos positivos” (VP) y “verdaderos negativos” (VN) son los aciertos en cada dirección, y los “falsos positivos” (FP) y “falsos negativos” (FN) son

los errores. Con esas cuatro cantidades se construyen las tres métricas reportadas en la tabla: la sensibilidad, $VP/(VP + FN)$, mide qué proporción de quienes efectivamente trabajaban según la ECV fueron correctamente identificados como ocupados por la imputación; la especificidad, $VN/(VN + FP)$, mide lo mismo para quienes no trabajaban; y el acuerdo global, $(VP + VN)/N$, resume el porcentaje total de coincidencias, calculándose las tres ponderadas por los factores de expansión indicados. Como la actividad principal (P6240) ya interviene en la distancia usada para elegir al donante, comparar contra ella bajo el método 6D es, en parte, una comprobación interna del propio método y no una prueba externa independiente; la variante 5D, junto con la reconstrucción laboral más amplia y las variables reservadas de esta sección, sí aporta evidencia algo más independiente, aunque tampoco constituye una prueba ciega diseñada antes de elegir el método de emparejamiento. Por ejemplo, en 2023 con el método 6D la sensibilidad es 93,00 % (de cada 100 personas que efectivamente trabajaban según la ECV, 93 son identificadas correctamente como ocupadas), la especificidad es 86,91 % y el acuerdo global es 90,38 %; al remover la actividad principal de la distancia (5D), estas tres cifras caen a 74,40 %, 61,13 % y 68,68 % respectivamente, una pérdida de entre 19 y 26 puntos porcentuales que muestra cuánto de la capacidad de reconstrucción laboral depende específicamente de esa variable. La última columna reporta qué porcentaje de las personas que no coinciden en su actividad principal exacta sí tienen registrada en la ECV alguna otra actividad relacionada con el trabajo (21,01 % en 2023 bajo 6D), lo que matiza los desacuerdos como parciales y no como errores totales de asignación.

Tabla 7: Reconstrucción laboral ponderada: distancia 6D y sensibilidad sin actividad principal, 5D.

Año	Distancia	Sensibilidad %	Especificidad %	Acuerdo %	Recupera otra actividad principal %
2022	6D	92.52	87.57	90.37	18.34
2022	5D	72.75	62.19	68.16	54.62
2023	6D	93.00	86.91	90.38	21.01
2023	5D	74.40	61.13	68.68	56.33
2024	6D	92.63	87.44	90.47	19.20
2024	5D	74.08	63.10	69.50	55.82
2025	6D	93.26	85.93	90.28	21.40
2025	5D	74.98	62.36	69.86	55.67

La siguiente tabla evalúa tres variables que no participaron en la construcción de la distancia del emparejamiento (afiliación pensional, posición ocupacional y horas trabajadas), comparando el valor imputado contra el que la ECV reporta de forma independiente en un grupo de hogares reservados de 2023; estos acuerdos condicionan necesariamente a las personas reconocidas como ocupadas en ambas fuentes y con respuestas comparables, de modo que la cobertura reportada indica esa selección y los acuerdos no describen automáticamente a todos los ocupados de la ECV. Por ejemplo, sobre 18.743 personas con una cobertura del 93,28 %, el acuerdo en afiliación pensional es 65,26 % y en posición ocupacional (grupos) es 47,79 %, sensiblemente más bajo porque distingue categorías más finas, mientras que en horas trabajadas el error absoluto medio es de 12,41 horas semanales con un sesgo promedio de apenas 1,96 horas: la imputación no sobreestima ni subestima sistemáticamente las horas, aunque los errores individuales pueden ser considerables. Al no haber intervenido en la selección del donante, estas variables ofrecen una prueba algo más independiente de qué tan bien se conserva la información laboral en general, más allá de la actividad principal usada para emparejar.

Tabla 8: Variables excluidas de la distancia: evaluación en hogares reservados, 2023, método 6D.

Variable	N	Cobertura %	Acuerdo %	MAE horas	Sesgo horas
pension	18.743	93.28	65.26	—	—
posicion_grupos	18.738	93.26	47.79	—	—
horas	18.743	93.28	—	12.415	1.9609

La siguiente tabla mide, mediante la afinidad de Hellinger, cuán similares son las distribuciones marginales ponderadas de variables clave entre el conjunto donante y el conjunto ya imputado. Para una misma variable

categoría, P es su distribución de frecuencias ponderadas en el conjunto donante (la muestra GEIH que aporta la información laboral) y Q es la distribución de esa misma variable en el conjunto ya imputado (la base ECV integrada); para cada categoría j (por ejemplo, “hombre” y “mujer” en el caso de sexo biológico), p_j es la proporción ponderada de esa categoría dentro de P y q_j es la proporción ponderada dentro de Q , sumando cada una 1 dentro de su propia distribución:

$$\rho(P, Q) = \sum_j \sqrt{p_j q_j}, \quad 0 \leq \rho \leq 1.$$

La afinidad suma, para todas las categorías, la raíz de $p_j q_j$, es decir la media geométrica de las dos proporciones; ese valor es exactamente 1 cuando P y Q coinciden categoría por categoría, y disminuye cuanto más se alejan entre sí. Un ejemplo real ilustra el mecanismo: para sexo biológico en 2023, la muestra donante (GEIH) tiene 48,67 % de hombres y 51,33 % de mujeres (ponderado), mientras que la base receptora ya imputada (ECV) tiene 48,72 % de hombres y 51,28 % de mujeres; aunque estas proporciones no son idénticas entre los dos conjuntos, están tan cerca que $\rho = \sqrt{0,4867 \times 0,4872} + \sqrt{0,5133 \times 0,5128} = 0,486961 + 0,513039 = 0,999999 \dots$, que redondeado a cuatro decimales da exactamente el 1,0000 reportado en la tabla. Cuando las proporciones difieren más entre los dos conjuntos, la media geométrica de esa pareja de proporciones queda más por debajo de su promedio aritmético, y esa pérdida se acumula categoría por categoría. Valores altos indican similitud marginal; no prueban independencia condicional ni conservación de relaciones entre variables exclusivas, y el umbral 0,95, cuando se utiliza, es descriptivo. Así se explica el resultado reportado: en zona (cabecera/resto), sexo biológico, tramos de edad, jefatura del hogar y pertenencia a la PET las proporciones ponderadas del conjunto donante y del conjunto imputado son tan cercanas entre sí que la afinidad redondea a 1,0000, mientras que en nivel educativo (5 niveles) las diferencias de proporción entre categorías son algo mayores y, acumuladas, hacen caer la afinidad a 0,9985, levemente por debajo de 1 pero aún muy por encima del umbral descriptivo de 0,95.

Tabla 9: Afinidad marginal ponderada de Hellinger, 2023.

Variable	Afinidad
Zona (Cabecera / Resto)	1.0000
Sexo Biológico	1.0000
Tramos de Edad	1.0000
Nivel Educativo (5 Niveles)	0.9985
Jefatura del Hogar (es_jefe)	1.0000
Pertenencia a la PET (≥ 15 años)	1.0000

El ingreso laboral es la variable transferida más relevante para el análisis económico posterior, pues de ella dependen los salarios, las brechas y los efectos estimados en el DiD. Sin embargo, a diferencia de edad, educación, jefatura, tamaño del hogar, PET o actividad principal, el ingreso no forma parte del vector de distancia z_i usado para elegir al donante: nunca se optimiza para que se parezca al del receptor, por lo que revisar su distribución es una comprobación más independiente que las anteriores. Podrían revisarse de la misma manera otras variables continuas transferidas, por ejemplo horas trabajadas, ya evaluada mediante error medio en la Tabla 8, pero el ingreso se prioriza aquí por su papel central en los resultados sustantivos del documento. La siguiente figura compara, para la misma variable, el logaritmo del ingreso laboral positivo a precios constantes de octubre de 2025, dos versiones: la que reporta directamente la muestra donante de la GEIH, que es el universo completo de posibles donantes, y la que queda ya asignada dentro de la base integrada de la ECV, que son los valores efectivamente transferidos a cada persona receptora, sujetos a los pesos de la ECV y a que un mismo donante puede repetirse en varios receptores, como se documentó en la Tabla 4. Esta densidad excluye ingresos cero y ausentes y no verifica su conservación, y precisamente esa reutilización de donantes populares puede modificar colas y correlaciones en la versión imputada aun cuando cada valor individual transferido provenga sin alteración de la fuente donante. Si el emparejamiento conserva razonablemente la estructura salarial, ambas densidades deberían tener una forma similar, aunque no necesariamente idéntica: de hecho, la correlación entre el ingreso imputado y el ingreso nativo de la ECV reportada en la Tabla 6 es de apenas 0,274

según el coeficiente de Pearson, lo que anticipa que las dos densidades pueden coincidir de forma agregada sin que exista una correspondencia estrecha a nivel individual.




Figura 1: Densidades de log ingreso laboral positivo: GEIH donante y ECV integrada, a precios de octubre de 2025.

La siguiente tabla contrasta, año por año, la tasa de desempleo calculada directamente sobre la muestra donante de la GEIH contra la misma tasa ya calculada sobre la base integrada de la ECV. Por ejemplo, en 2022 la tasa de desempleo es 9,99 % en la GEIH y 10,00 % en la ECV integrada, una diferencia de apenas 0,01 puntos porcentuales; en 2025, en cambio, la brecha es mayor: 7,80 % frente a 7,25 %, es decir -0,55 puntos porcentuales. Una diferencia pequeña entre ambas indica que el proceso de imputación no distorsiona de forma importante este agregado nacional, aunque no garantiza que la coincidencia se mantenga igual de bien en subgrupos más desagregados.

Tabla 10: Desempleo en el conjunto donante e imputado: contraste descriptivo de tasas ponderadas.

Año	GEIH %	ECV imputada %	Diferencia pp
2022	9.99	10.00	0.0052573
2023	9.16	9.48	0.32105
2024	8.81	8.85	0.042436
2025	7.80	7.25	-0.55186

La siguiente tabla evalúa qué tan sensible es el resultado a la regla de desempate: cuando dos o más donantes potenciales quedan exactamente a la misma distancia de una persona receptora, se examina qué cambiaría si se hubiera elegido, en cambio, al vecino alternativo equidistante; “empates” es el porcentaje de personas afectadas por esta situación, y el cambio de ocupación mide cuánto se movería la tasa de ocupación agregada si se usara siempre esa alternativa en lugar del criterio de desempate original. Por ejemplo, en 2023 el 47,59 % de las personas (55,07 % en términos ponderados) tuvo al menos un donante alternativo empatado, lo que afectó individualmente a 7.591 personas; sin embargo, el efecto sobre el agregado es mínimo, con un cambio de apenas 0,05 puntos porcentuales en la tasa de ocupación si se hubiera usado siempre esa alternativa. Una pequeña variación agregada como esta puede, sin embargo, coexistir con numerosos cambios individuales de donante o situación laboral, y la alternativa de empate no constituye imputación múltiple, por lo que sus diferencias no se incorporan automáticamente a los errores estándar de las regresiones.

Tabla 11: Sensibilidad a otro vecino equidistante: incidencia y cambio de tasa de ocupación.

Año	Empates %	Empates ponderados %	Sin educación en métrica	Cambios individuales	Cambio ocupación (pp)
2022	48.85	55.92	29765	7498	-0.038778
2023	47.59	55.07	28515	7591	0.053417
2024	46.80	54.61	25277	6297	0.060273
2025	47.99	55.71	25918	7695	-0.02742

En conjunto, la evaluación de esta sección muestra un patrón consistente a lo largo de todas las tablas anteriores: las propiedades mejor conservadas son precisamente las que intervienen en el vector de distancia z_i usado para elegir al donante. La coherencia contable es prácticamente perfecta, sin menores de edad con salario u ocupación imputados y con apenas 3 registros de código CIUO inválido; la concordancia de la condición ocupacional alcanza 90 por ciento o más bajo el método de 6 dimensiones, y las distribuciones marginales ponderadas de zona, sexo, edad, jefatura del hogar y pertenencia a la población en edad de trabajar resultan prácticamente indistinguibles entre el conjunto donante y el conjunto imputado, con afinidades de Hellinger de 1,0000. Las tasas agregadas de desempleo entre la GEIH y la ECV integrada también difieren en menos de un punto porcentual en todos los años revisados, y la sensibilidad del resultado a la regla de desempate es mínima. Por el contrario, las variables que no participan en la distancia muestran un desempeño más limitado: la sensibilidad y el acuerdo laboral caen entre 19 y 26 puntos porcentuales cuando se retira la actividad principal de la distancia, el acuerdo en afiliación pensional y posición ocupacional en los hogares reservados se ubica entre 48 y 65 por ciento, y la correlación entre el ingreso imputado y el ingreso nativo de la ECV es apenas de 0,274. Este contraste sugiere que el emparejamiento preserva de forma confiable la condición laboral básica y los agregados distribucionales, pero conserva con menor precisión el nivel individual de variables continuas que no orientaron la selección del donante, como el ingreso. La evaluación, por tanto, documenta qué propiedades se conservan y dónde persisten discrepancias; no certifica equivalencia de las encuestas.

2.2. Construcción y asignación de los índices de exposición

Esta sección describe cómo se construyen y asignan los índices de exposición a la inteligencia artificial que sustentan las estimaciones econométricas posteriores. Se parte de cinco indicadores ocupacionales tomados de la literatura internacional, AIOE, Webb-IA, LLM, software y robots, más una envolvente máxima de sensibilidad, trasladados a las 455 ocupaciones del catálogo CIUO-08 A.C. mediante correspondencias O*NET-SOC, SOC e ISCO-08. Cada indicador se normaliza en una escala percentil fija sobre las ocupaciones con puntuación observada, con una versión Min-Max como sensibilidad de escala, sin recalcularse por año ni por submuestra. La asignación individual depende de la situación laboral, usando la ocupación actual para ocupados y la última ocupación desempeñada para desocupados, y hereda la incertidumbre del emparejamiento descrito en la sección anterior. Finalmente, se explica cómo se define la muestra común comparable entre los cinco índices y cómo el índice individual se agrega a exposición departamental o de cohorte para alimentar cada familia de modelos utilizada más adelante.

2.2.1. Fundamentos y elección de indicadores

El índice AIOE, propuesto por Felten et al. (2021), se construye comparando el perfil de habilidades que exige cada ocupación con las capacidades que despliegan los sistemas de inteligencia artificial actuales: cuanto más se solapan ambos perfiles, mayor es el valor del índice, sin que esto implique necesariamente una relación negativa con el empleo o el salario, pues una ocupación muy expuesta puede verse afectada tanto por sustitución como por complementación tecnológica. Webb (2020) sigue una lógica distinta: construye sus tres medidas, exposición a IA, a software y a robots, a partir de qué tan similares son las tareas descritas en las funciones de cada ocupación y el lenguaje técnico usado en patentes de esas tres tecnologías. Eloundou et al. (2024) miden en cambio la exposición de las tareas de cada ocupación a modelos de lenguaje de gran escala; la variante utilizada aquí, GPT-4 beta, combina dos componentes, las tareas que el modelo puede resolver directamente

y las que puede resolver de forma indirecta apoyándose en software adicional, ponderando estas últimas a la mitad, $E1 + 0.5E2$. En los tres casos conviene subrayar que estas puntuaciones son medidas de similitud o solapamiento entre tareas y capacidades tecnológicas, no probabilidades calibradas de que una ocupación específica vaya a automatizarse o desaparecer.

Tabla 12: Indicadores de exposición a la inteligencia artificial utilizados y su referencia bibliográfica.

Indicador	Campo original	Referencia	Uso principal en el análisis
AIOE	AIOE	Felten et al. (2021)	Referencia común para desempleo, no cotización e ingreso
Webb-IA	<code>ai_score</code>	Webb (2020)	Contraste de exposición a IA basada en patentes
LLM	<code>dv_rating_beta</code>	Eloundou et al. (2024)	Contraste de exposición a modelos de lenguaje
Software	<code>software_score</code>	Webb (2020)	Extensión de automatización por software
Robots	<code>robot_score</code>	Webb (2020)	Extensión de automatización robótica
Envolvente máxima	Máximo de AIOE, Webb-IA y LLM normalizados	Felten et al. (2021); Webb (2020); Eloundou et al. (2024)	Sensibilidad a una regla de agregación; no indicador principal

Cada uno de los cinco indicadores se incluye en su propia regresión, estimada por separado; ninguno se agrega junto a los demás en una misma especificación. Esto implica dos cosas: primero, que los cinco no deben leerse como alternativas mutuamente excluyentes entre las que haya que elegir una sola versión correcta, sino como cinco formas distintas, y en parte complementarias, de medir exposición tecnológica; y segundo, que sus coeficientes no pueden sumarse entre sí, porque cada uno proviene de una regresión distinta y no de una descomposición de un mismo efecto total. Incluir los cinco simultáneamente en una sola regresión respondería a una pregunta diferente, la de qué asociación conserva cada índice una vez controlado por los demás, y resultaría inestable: como muestra la Tabla 14, AIOE y LLM están correlacionados en 0,88, de modo que forzarlos a competir por la misma variación dentro de una sola ecuación produciría coeficientes poco confiables. Por eso la especificación principal de este documento estima cada indicador por separado.

2.2.2. Correspondencias ocupacionales y asignación individual

La tabla de referencia ocupacional contiene las 455 ocupaciones del catálogo CIUO-08 A.C. usado por el DANE. Como los tres índices internacionales publican sus puntuaciones en sistemas de clasificación distintos, SOC-2010 para AIOE y O*NET-SOC para Webb-IA y LLM, primero se traducen a ISCO-08 mediante un crosswalk oficial de la Oficina de Estadísticas Laborales de Estados Unidos, y luego de ISCO-08 a CIUO-08 A.C., que sigue una estructura casi idéntica a la de ISCO-08. De las 455 ocupaciones colombianas, 436 encuentran una correspondencia directa uno a uno con un código ISCO-08; para otras 4 no existe ese código exacto y se aproxima con el promedio de las ocupaciones ISCO-08 que comparten los primeros tres dígitos, una aproximación más gruesa que puede perder matices propios de la clasificación colombiana; y las 15 restantes, principalmente ocupaciones de las fuerzas militares fuera del alcance de las fuentes internacionales usadas, no tienen ninguna correspondencia posible. Cuando la correspondencia es múltiple, es decir cuando varios códigos internacionales apuntan a la misma ocupación colombiana, se promedian sus puntuaciones sin ponderar por el número de personas empleadas en cada uno. Las ocupaciones sin correspondencia, o con correspondencia pero sin puntuación publicada en la fuente original, quedan explícitamente sin dato, sin recibir cero ni el promedio nacional, para no simular información que no existe.

El código de ocupación usado para asignar el índice a cada persona depende de su situación laboral, siguiendo la definición del diccionario oficial GEIH del DANE, DANE (2023): a los ocupados se les asigna el índice de su ocupación actual, `OFICIO_C8`; a los desocupados, el de la última ocupación que desempeñaron, `OFICIO02_C8`, bajo el supuesto de que su exposición tecnológica relevante es la de esa ocupación previa. Como sensibilidad, se prueba también asignar la ocupación que la persona desocupada dice estar buscando, `OFICIO01_C8`, en vez de su última ocupación. En ningún caso se completa el código de ocupación ausente de una persona con la ocupación que estuviera buscando; cuando el código actual falta, la persona simplemente queda sin índice.

Estas reglas tienen tres consecuencias para la interpretación de los resultados. Primero, el desempleo econométrico solo puede analizarse entre personas cuya ocupación actual o anterior sea identificable y puntuable, lo que excluye en particular a quienes buscan su primer empleo y no tienen ninguna ocupación previa que codificar; por tanto, no representa a toda la fuerza laboral desempleada, sino a un subconjunto con historia laboral registrada. Segundo, para las personas cuya información laboral proviene de la imputación GEIH-ECV descrita en la Sección 2.1, el índice de exposición hereda la incertidumbre de esa asignación por vecino más cercano: la ocupación usada para puntuar es la del donante asignado, no una observación directa de la persona receptora. Finalmente, una advertencia temporal específica del índice LLM: al aplicarse retrospectivamente sobre ocupaciones de 2022, mide qué tan expuestas están las tareas de esa ocupación a una tecnología de lenguaje que en su forma actual es posterior a 2022; esto caracteriza el contenido de tareas de la ocupación, no demuestra que esa tecnología ya se hubiera adoptado efectivamente en 2022.

La Tabla 13 reporta, para cada uno de los cinco indicadores, el número de las 455 ocupaciones del catálogo CIUO-08 A.C. con puntuación observada, junto con los estadísticos descriptivos de esa puntuación normalizada. La normalización reportada es la percentil, formalizada en la sección siguiente; la variante Min-Max se calcula únicamente como análisis de sensibilidad y no es la que aquí se resume. Cabe subrayar que esta tabla no corresponde a ningún año particular de la GEIH o la ECV: describe un catálogo ocupacional fijo, construido una sola vez a partir de las puntuaciones internacionales de AIOE, Webb-IA y Eloundou et al., y reutilizado sin modificación para asignar exposición a las personas entre 2022 y 2025. AIOE, Webb-IA, software y robots cuentan con puntuación para 426 ocupaciones, frente a 396 en el caso de LLM, lo que refleja la cobertura internacional más limitada de esta última fuente. En los cinco casos la media es exactamente 0,5 y la desviación estándar ronda 0,29, patrón esperado de la normalización percentil, que distribuye los rangos de forma aproximadamente uniforme entre 0 y 1.

Tabla 13: Disponibilidad y distribución de los índices en el catálogo ocupacional fijo.

Índice	Ocupaciones	Media	DE	Mínimo	Máximo
AIOE	426	0.5	0.28969	0	1
Webb-IA	426	0.5	0.28969	0	1
LLM	396	0.5	0.28977	0.010127	1
Software	426	0.5	0.28969	0	1
Robots	426	0.5	0.28969	0	1

2.2.3. Normalización fija y sensibilidad de escala

Para un indicador crudo S_o^k , se consideran las N_k ocupaciones con puntuación observada en la tabla de referencia. La normalización percentil utilizada es

$$I_o^{k,P} = \frac{\text{rango}_{\text{promedio}}(S_o^k) - 1}{N_k - 1}.$$

Los empates reciben rango promedio; por ello, los extremos empatados pueden no alcanzar exactamente cero o uno. No se pondera por empleo y no se recalcula el rango dentro de cada año, resultado laboral o submuestra. La escala permanece fija al asignar el índice a personas y al agregarlo. Un ejemplo real ilustra el cálculo: la ocupación 2512, desarrolladores de software, tiene una puntuación cruda de AIOE de 1,242115; entre las $N_k = 426$ ocupaciones con AIOE observado, esa puntuación ocupa el rango 386, de modo que

$I_o^{AIOE,P} = (386 - 1)/(426 - 1) = 385/425 = 0,9059$. Los empates se ven, por ejemplo, en cuatro ocupaciones distintas que comparten el mismo valor crudo de AIOE, 0,9646872; sin empate ocuparían las posiciones 324, 325, 326 y 327, pero al empatar reciben a las cuatro el promedio de esas posiciones, rango = 325,5, y por tanto el mismo percentil, $I_o^{AIOE,P} = (325,5 - 1)/425 = 0,7635$.

Como sensibilidad se utiliza

$$I_o^{k,MM} = \frac{S_o^k - \min_o S_o^k}{\max_o S_o^k - \min_o S_o^k}.$$

El percentil describe posición relativa y reduce la influencia de distancias extremas; Min-Max conserva las distancias relativas del indicador original. Una escala común no vuelve equivalentes los constructos. Con la misma ocupación 2512, el mínimo y el máximo de AIOE entre las 426 ocupaciones observadas son $-2,1227635$ y $1,446232$, de modo que $I_o^{AIOE,MM} = (1,242115 - (-2,1227635))/(1,446232 - (-2,1227635)) = 3,364879/3,568996 = 0,9428$; a diferencia del percentil, aquí sí importa qué tan lejos está el valor de los extremos, no solo su posición relativa. La envolvente se define como

$$I_o^{max} = \max\{I_o^{AIOE}, I_o^{WebbIA}, I_o^{LLM}\},$$

solo cuando los tres componentes están observados. Un faltante no se interpreta como exposición nula. Como la envolvente se calcula por separado en cada escala, conviene precisar a cuál corresponde cada número del ejemplo. En la escala percentil, la ocupación 1112, directores del gobierno, tiene $I_o^{AIOE,P} = 0,7718$, $I_o^{WebbIA,P} = 0,5271$ y $I_o^{LLM,P} = 0,7190$; como los tres están observados, la envolvente percentil toma el máximo de los tres, AIOE, y queda en $I_o^{max,P} = 0,7718$. En cambio, la ocupación 2211, médicos generales, tiene $I_o^{AIOE,P} = 0,7694$ y $I_o^{WebbIA,P} = 0,3365$, pero no tiene puntuación LLM; aunque dos de los tres componentes están disponibles y uno de ellos es relativamente alto, la envolvente percentil queda sin dato, no en 0,7694, porque la regla exige los tres componentes observados y falta uno. La misma regla se aplica, de forma independiente, en la escala Min-Max: para la ocupación 1112, $I_o^{AIOE,MM} = 0,8694$, $I_o^{WebbIA,MM} = 0,2873$ y $I_o^{LLM,MM} = 0,4823$, de modo que $I_o^{max,MM} = 0,8694$, también tomado de AIOE; para la ocupación 2211, al faltar LLM también en esta escala, $I_o^{max,MM}$ queda igualmente sin dato. Se publican ambas escalas, percentil y Min-Max, para sensibilidad, sin sustituir la elección principal por el resultado más significativo.

Todas las estimaciones vigentes del documento, a nivel de persona, departamento o cohorte, leen la misma referencia ocupacional fija generada por `indices_comunes.py`, con la fórmula de rango promedio ya documentada, que ubica a la ocupación con la puntuación más baja exactamente en 0 y a la de mayor puntuación exactamente en 1. La agregación departamental y de cohorte de la siguiente sección no recalcula el percentil de ninguna otra forma: simplemente promedia esas mismas columnas ya normalizadas, ponderando por la participación de cada ocupación en el empleo. La Tabla 14 identifica, para cada familia de estimación, qué índice y qué escala se usa como especificación principal, y el script que produce esos resultados.

Tabla 14: Índice principal, escala de normalización y script de origen por familia de estimación.

Familia de estimación	Índice principal	Escala	Script que produce el resultado
DiD estático y dinámico	AIOE	Percentil	<code>estimar_indices_comparables.py</code>
DDD, habilitación TIC y educación	AIOE	Percentil	<code>estimar_indices_comparables.py</code>
Shift-share departamental	AIOE*	Percentil	<code>estimar_indices_comparables.py</code>
Within de cohorte	AIOE*	Percentil	<code>estimar_indices_comparables.py</code>
Primeras diferencias de cohorte	AIOE*	Percentil	<code>estimar_indices_comparables.py</code>
DML/PLR	AIOE	Percentil	<code>estimar_indices_ml.py</code>
R-learner	AIOE	Percentil	<code>estimar_indices_ml.py</code>

Nota. * En shift-share, within y primeras diferencias, el índice usado como variable de tratamiento no es el percentil ocupacional $I_o^{AIOE,P}$ directamente, sino su agregación departamental o de cohorte, $I_{d,2022}^{AIOE}$, descrita en la sección 2.2.5.

La siguiente tabla reporta las correlaciones entre los cinco índices percentiles, calculadas sobre las 395 ocupaciones con cobertura común, y evidencia que no son medidas intercambiables de exposición. Por ejemplo, AIOE y LLM están altamente correlacionados, 0,88, lo que sugiere que ambos capturan un patrón similar de exposición a tareas cognitivas, mientras que AIOE y Webb-IA prácticamente no lo están, -0,02; AIOE se correlaciona negativamente y de forma marcada con robots, -0,78, consistente con que AIOE mide exposición a capacidades de IA cognitivas, más asociadas a ocupaciones no rutinarias, mientras que robots captura automatización física de tareas rutinarias. Estas diferencias respaldan estimarlos en regresiones separadas en lugar de combinarlos en un único índice.

Tabla 15: Correlaciones de los cinco índices percentiles sobre ocupaciones con cobertura común.

Índice	AIOE	Webb-IA	LLM	Software	Robots
AIOE	1	-0.020055	0.88265	-0.40555	-0.77734
Webb-IA	-0.020055	1	-0.0029837	0.65235	0.25911
LLM	0.88265	-0.0029837	1	-0.34786	-0.72998
Software	-0.40555	0.65235	-0.34786	1	0.68569
Robots	-0.77734	0.25911	-0.72998	0.68569	1

Las correlaciones se calculan entre las 395 ocupaciones con cobertura común, sin ponderación por empleo; no equivalen a correlaciones ponderadas entre personas.

2.2.4. Cobertura y muestra comparable

La muestra común exige exposición observada en los cinco indicadores y los controles requeridos por el modelo. Se fija por resultado laboral, por lo que desempleo, no cotización e ingreso no tienen necesariamente igual tamaño muestral. Esta regla permite comparar índices sobre las mismas personas dentro de cada resultado; también restringe la población a la intersección de coberturas y debe interpretarse como tal.

La siguiente tabla muestra, año por año y separando ocupados de desocupados, qué porcentaje de personas cuenta con exposición observada en los cinco índices antes de aplicar los controles del modelo. Por ejemplo, en 2022 la cobertura entre ocupados es de 95,80 %, 94,80 % ponderada, sobre un universo de 106.120 personas; entre desocupados la cobertura es sustancialmente menor, 79,69 %, 80,50 % ponderada, porque un desocupado solo recibe índice si su última ocupación es identificable y puntuable, lo que deja fuera con mayor frecuencia a quienes buscan su primer empleo o no reportan ocupación previa.

Tabla 16: Cobertura de exposición individual por año y universo laboral.

Año	Universo	N universo	N común	Cobertura %	Cobertura ponderada %
2022	ocupados	106.120	101.658	95.80	94.80
2022	desocupados	10.978	8.748	79.69	80.50
2023	ocupados	103.550	99.419	96.01	94.92
2023	desocupados	10.269	8.433	82.12	81.77
2024	ocupados	100.981	96.998	96.06	95.64
2024	desocupados	8.979	7.455	83.03	82.61
2025	ocupados	106.915	102.492	95.86	95.24
2025	desocupados	7.822	6.399	81.81	81.72

La cobertura anterior se calcula antes de exigir controles y respuestas válidas del modelo. La muestra econométrica añade esas restricciones; ambos porcentajes responden a denominadores diferentes.

La siguiente tabla contrasta, para cada resultado laboral, el universo disponible en la base integrada contra la muestra común efectivamente utilizada en las regresiones, ya después de exigir exposición en los cinco índices y respuestas válidas en los controles del modelo. Por ejemplo, para desempleo el universo es de 455.614 personas y la muestra común retiene el 94,73 %, 431.601 personas, mientras que para ingreso laboral el universo es de 394.119 personas con una retención de 95,91 %; las diferencias en el tamaño del universo entre resultados reflejan que cada uno aplica sus propios filtros de elegibilidad, ya que ingreso laboral, por ejemplo, solo aplica a ocupados con salario positivo.

Tabla 17: Universos disponibles y muestras comunes efectivamente utilizadas en las regresiones individuales.

Resultado	N universo	N común	Retención %
Desempleo	455.614	431.601	94.73
No cotización	412.939	396.064	95.91
Ingreso laboral	394.119	377.991	95.91

2.2.5. Del índice individual a la exposición agregada

Hasta aquí el índice de exposición se define a nivel de cada ocupación. Esta sección explica cómo se convierte en un índice de exposición a nivel departamental o de cohorte, que es la variable de tratamiento efectivamente usada en los modelos shift-share, within y primeras diferencias descritos más adelante. La lógica es sencilla: un departamento o una cohorte no tiene una sola ocupación, sino una mezcla de muchas, así que su exposición se calcula como el promedio de la exposición de cada ocupación presente ahí, ponderado por qué tan importante es esa ocupación dentro del empleo del departamento en el año base, 2022. La exposición departamental basal utiliza ocupados de 2022 con cobertura común:

$$I_{d,2022}^k = \sum_o s_{do,2022} I_o^k, \quad s_{do,2022} = \frac{\sum_{i \in (d,o),2022} w_i 1(i \in \mathcal{V})}{\sum_{i \in d,2022} w_i 1(i \in \mathcal{V})}.$$

Aquí $s_{do,2022}$ es la participación ponderada de la ocupación o dentro del empleo total del departamento d en 2022, e I_o^k es la exposición de esa ocupación bajo el índice k ; $\mathcal{V}$ identifica el universo con indicadores observados. Un ejemplo real con Bogotá ilustra el cálculo. Entre las ocupaciones más importantes de la ciudad en 2022 están vendedores de tiendas y almacenes, con una participación de 4,99 % del empleo puntuable y una exposición de 0,55; auxiliares y asistentes administrativos, con 2,86 % de participación y exposición de 0,62; empleadas domésticas, con 2,73 % de participación pero una exposición muy baja, 0,05; y una ocupación contable altamente expuesta, con 2,57 % de participación y exposición de 0,99. De las 4.018.594 personas ocupadas de Bogotá en 2022, el 0,78 % queda sin índice por no tener una ocupación puntuable, y se excluye tanto del numerador como del denominador de $s_{do,2022}$, en lugar de solo del numerador, que subestimaría artificialmente el índice. Sumando la contribución ponderada de todas las ocupaciones puntuables, el resultado final para Bogotá es $I_{Bogot,2022}^{max} = 0,6652$; en contraste, Nariño, el departamento con mayor exposición del país en 2022, alcanza 0,7192, mientras que San Andrés, el de menor exposición, llega a 0,5632. Para una cohorte c se aplica la misma media ponderada dentro de la cohorte. Las participaciones $s_{do,2022}$ se fijan en el año base 2022 y no se recalculan en los años siguientes, mientras que los índices ocupacionales I_o^k se mantienen constantes por construcción; esto sigue la lógica estándar de un diseño shift-share, en la que la variación explotada proviene de la exposición tecnológica de cada ocupación, no de cómo cambia la composición del empleo departamental año a año.

La siguiente figura muestra esta misma exposición agregada, I_d^{AIOE} , pero calculada con la composición del empleo de 2025 en lugar de la basal de 2022, para dar una fotografía descriptiva más reciente de cómo se distribuye la exposición a IA entre departamentos; los modelos shift-share, within y primeras diferencias, sin embargo, siguen usando las participaciones fijas de 2022 por la razón metodológica ya explicada. El índice mostrado es AIOE en escala percentil, el mismo usado como especificación principal en todas las familias de estimación de este documento. Los departamentos se colorean de azul, menor exposición, a rojo, mayor exposición: Bogotá encabeza el ranking nacional con 0,531, seguida de San Andrés (0,448) y Atlántico (0,440), mientras que Vichada (0,243), Cauca (0,292) y Huila (0,306) están entre los de menor exposición relativa.

San Andrés y Providencia se muestran, cada una, en un recuadro ampliado con su contorno geográfico real, tomado de Natural Earth ante la baja resolución de la fuente cartográfica departamental del proyecto para este archipiélago; Santa Catalina y los demás cayos no se delimitan por separado en ninguna de las dos fuentes. El patrón general muestra mayor exposición en departamentos con economías urbanas y de servicios (Bogotá, eje cafetero, Valle del Cauca, Santander), y menor exposición en departamentos con estructuras productivas más rurales o extractivas.

2.3. Construcción y evaluación del pseudo-panel

2.3.1. Teoría, definición de cohortes y agregación

Deaton (1985) propone seguir medias de grupos definidos por características comparables en cortes transversales sucesivos. Verbeek (2008) explica que las propiedades del estimador dependen de la estabilidad de esos grupos y de la precisión de sus medias. Aquí la cohorte combina departamento de residencia, sexo y generación aproximada de nacimiento, calculada como año menos edad. No se aplica un segundo vecino más próximo entre años: las celdas se enlazan mediante su misma llave de cohorte.

Generación	Nacimiento aproximado
1	Hasta 1964
2	1965–1974
3	1975–1984
4	1985–1994
5	Desde 1995

Se impone PET desde 15 años antes de agregar. La versión cerrada restringe nacimiento hasta 2007; reduce la entrada de nuevas generaciones a PET, pero no elimina migración, mortalidad ni cambios de composición. El departamento es residencia observada, no una característica individual inmutable.

Para una variable Y con universo válido $\mathcal{U}_Y$, la media de cohorte es

$$\bar{Y}_{ct} = \frac{\sum_{i \in (c,t)} w_i Y_i 1(i \in \mathcal{U}_Y)}{\sum_{i \in (c,t)} w_i 1(i \in \mathcal{U}_Y)}.$$

El desempleo divide desocupados por fuerza laboral; la no cotización usa ocupados con respuesta pensional 1/2. Para ingreso se calcula primero la media ponderada de valores positivos y después su logaritmo:

$$Y_{ct}^{sal} = \log \left(\frac{\sum_{i \in (c,t), w_i^{lab} > 0} f_i w_i^{lab}}{\sum_{i \in (c,t), w_i^{lab} > 0} f_i} \right).$$

En esta expresión f_i es el factor de expansión y w_i^{lab} el ingreso laboral real. El logaritmo de la media no coincide con la media de los logaritmos; por ello, el resultado de cohorte no es idéntico al resultado salarial individual. La exposición basal $I_{c,2022}^k$ se incorpora con la misma codificación de generaciones definida arriba.

2.3.2. Resultados de construcción y evaluación

Tabla 18: Estructura y tamaño de las celdas de los paneles principal y cerrado.

Panel	Filas	Cohortes	Columnas	Mín. PET	Mediana PET	Máx. PET
Principal	1.320	330	78	134	519	1209

Tabla 18: Estructura y tamaño de las celdas de los paneles principal y cerrado.

Panel	Filas	Cohortes	Columnas	Mín. PET	Mediana PET	Máx. PET
Cerrado	1.320	330	78	134	514	1183

Treinta y tres dominios territoriales, dos sexos y cinco generaciones producen 330 cohortes y 1.320 celdas para cuatro años. Este balance de llaves no garantiza que todos los indicadores estén observados en cada celda ni que sus medias tengan la misma precisión.

Tabla 19: Disponibilidad, receptores y donantes distintos por resultado de cohorte.

Panel	Resultado	Celdas	Receptores mín.	Donantes mín.	Donantes mediana	Cobertura mín. %
principal	Desempleo	1320	31	20	168	100.00
principal	No cotización	1320	31	20	148	69.54
principal	Ingreso	1320	25	17	143	38.36
cerrada	Desempleo	1320	31	20	167	100.00
cerrada	No cotización	1320	31	20	148	69.54
cerrada	Ingreso	1320	25	17	142.5	38.36

El mínimo de receptores PET de una celda no debe usarse como tamaño muestral de todas sus tasas. Los universos de fuerza laboral, respuestas pensionales e ingreso positivo son menores; además, distintos receptores pueden compartir donante. Los errores de las medias pueden estar correlacionados y la agregación no elimina la incertidumbre de imputación. Los modelos ponderados por tamaño de celda son una aproximación; no equivalen a una corrección completa del diseño muestral.

El panel principal conserva 72 indicadores y seis campos estructurales. El ampliado añade 2.175 indicadores, acompañados de universos y clasificación metodológica. La existencia de muchas columnas no añade periodos ni información independiente. Se evita incorporar simultáneamente identidades contables y se excluyen de la selección inicial los indicadores cuya elegibilidad no está armonizada. El análisis econométrico de esta investigación utiliza resultados laborales y controles definidos, no todas las variables del catálogo.

3. Estimaciones econométricas clásicas

3.1. Diseño común, bases y criterio de interpretación

Las regresiones individuales utilizan los cuatro archivos ECV–GEIH integrados, con PET, ponderadores positivos, controles válidos y cobertura común de los cinco índices. El desempleo usa fuerza laboral con ocupación actual o anterior identificable; la no cotización, ocupados con respuesta pensional 1/2; y el ingreso, ocupados con ingreso laboral positivo. Los modelos de cohortes utilizan el panel principal, no una muestra longitudinal de individuos.

Los controles individuales incluyen edad, su término cuadrático, sexo, zona, jefatura y categorías educativas, junto con efectos de año, departamento y ocupación a dos dígitos. La edad se limita al rango utilizado por el código, 15–95 años, antes de construir el polinomio. La educación ausente se excluye de la muestra común de estas estimaciones. Los resultados de cohortes controlan edad media, proporción rural y proporción universitaria. Cada indicador se introduce por separado: AIOE es principal; Webb–IA y LLM son contrastes de IA; software y robots amplían el análisis a automatización.

Exposición departamental agregada a IA I_d^{AIOE} , Colombia 2025




Figura 2: Índice agregado departamental I_d^{AIOE} , a partir del percentil ocupacional AIOE, Colombia 2025. San Andrés y Providencia se muestran en recuadros ampliados, fuera de escala, con su contorno real.

Bertrand et al. (2004) destacan la importancia de la dependencia de los errores en diseños de diferencias en diferencias. Aquí se agrupan por ocupación de cuatro dígitos en microdatos y por departamento en cohortes. Se emplea corrección de covarianza agrupada CR1 y distribución t con $G - 1$ grados de libertad; las pruebas conjuntas utilizan los correspondientes grados de libertad. Los 33 grupos departamentales implican $t(32)$. La réplica Python–Stata verifica consistencia numérica, no exogeneidad ni incorporación completa del diseño complejo de encuesta.

En las tablas, **EE** indica error estándar, **IC** intervalo de confianza, **N** observaciones y **G** grupos. Los valores p son nominales, sin ajuste por la multiplicidad de índices y resultados. Por ello se distingue la especificación principal predefinida de los contrastes exploratorios; un resultado aislado significativo no se selecciona como conclusión general.

Un aumento de 0,1 unidades del índice percentil representa un contraste de posición ocupacional en una escala fija, no un aumento de diez puntos de adopción. Para resultados binarios, el cambio asociado es $100(0.1\beta) = 10\beta$ puntos porcentuales. Para log ingreso, $100[\exp(0.1\beta) - 1]\%$ expresa el cambio multiplicativo asociado. En el modelo individual se refiere al ingreso geométrico condicional, no a la media aritmética sin supuestos adicionales de retransformación; en el panel corresponde a la media de cohorte cuyo logaritmo es la variable dependiente. No significancia no demuestra efecto nulo: indica que el intervalo conserva magnitudes de ambos signos o incluye cero bajo esa especificación.

3.2. Diferencias en diferencias con exposición continua

3.2.1. Marco teórico, ecuación y base

Callaway et al. (2024) estudian las condiciones de interpretación de diferencias en diferencias con tratamientos continuos. En este ejercicio, la intensidad es una característica ocupacional fija y el periodo posterior se define desde 2023. Se estima

$$Y_{iott} = \alpha + \lambda_t + \eta_d + \gamma_{g(o)} + \rho I_o^k + \beta_k I_o^k Post_t + X'_{it} \theta + \varepsilon_{iott}, \quad Post_t = 1(t \geq 2023).$$

El término ρI_o^k separa diferencias de nivel y contrastes temporales. Los efectos de ocupación a dos dígitos no absorben necesariamente la variación a cuatro dígitos; omitir ese nivel basal altera el estimando. Para resultados binarios se utiliza un modelo lineal de probabilidad ponderado; sus coeficientes son diferencias locales ajustadas, no garantías de predicciones acotadas entre cero y uno.

Esta especificación difiere de una versión previa del análisis en dos decisiones simultáneas: el índice de referencia (aquí AIOE individual; antes, el envolvente máximo de los tres índices) y la granularidad del efecto fijo ocupacional (aquí, grupo a dos dígitos más el nivel I_o^k ; antes, un efecto fijo saturado a cuatro dígitos que ya absorbía dicho nivel). Ambos cambios afectan la magnitud de β_k de forma independiente; las comparaciones frente a resultados anteriores no aíslan cuál de los dos explica una diferencia observada.

La identificación causal requeriría justificar la evolución contrafactual por intensidad, ausencia de shocks correlacionados con exposición y estabilidad de composición. Solo 2022 es previo: no puede verificarse una trayectoria de tendencias paralelas anterior a 2023. El periodo posterior no identifica por sí mismo una intervención observada de IA. Los controles contemporáneos tampoco eliminan automáticamente selección ocupacional.

3.2.2. Resultados estáticos e interpretación

Tabla 20: DiD estático: AIOE principal e indicadores específicos separados, escala percentil fija y muestra común por resultado.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	AIOE	-0.0034 (0.0106)	[-0.0243; 0.0175]	0.7483	431.601	385
Desempleo	Webb-IA	0.0024 (0.0088)	[-0.0149; 0.0197]	0.7868	431.601	385
Desempleo	LLM	-0.0005 (0.0120)	[-0.0241; 0.0231]	0.9653	431.601	385
Desempleo	Software	0.0090 (0.0090)	[-0.0088; 0.0267]	0.3223	431.601	385
Desempleo	Robots	0.0046 (0.0101)	[-0.0153; 0.0245]	0.6516	431.601	385
No cotización	AIOE	0.0163 (0.0179)	[-0.0189; 0.0514]	0.3627	396.064	384
No cotización	Webb-IA	0.0038 (0.0181)	[-0.0317; 0.0394]	0.8321	396.064	384
No cotización	LLM	0.0200 (0.0192)	[-0.0178; 0.0578]	0.2996	396.064	384
No cotización	Software	0.0035 (0.0207)	[-0.0373; 0.0442]	0.8664	396.064	384
No cotización	Robots	-0.0101 (0.0180)	[-0.0455; 0.0252]	0.5736	396.064	384
Ingreso laboral	AIOE	0.0504 (0.0328)	[-0.0141; 0.1149]	0.125	377.991	383
Ingreso laboral	Webb-IA	-0.0579 (0.0302)	[-0.1173; 0.0015]	0.05587	377.991	383
Ingreso laboral	LLM	0.0503 (0.0354)	[-0.0194; 0.1200]	0.1566	377.991	383
Ingreso laboral	Software	-0.0856 (0.0349)	[-0.1543; -0.0169]	0.01477	377.991	383
Ingreso laboral	Robots	-0.0809 (0.0365)	[-0.1526; -0.0091]	0.02721	377.991	383

Desempleo. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **-0.034 puntos porcentuales** en probabilidad de desempleo dentro de la muestra con ocupación identificable, con intervalo [-0.243; +0.175] y $p=0.7483$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

No cotización. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **+0.163 puntos porcentuales** en no cotización pensional, con intervalo [-0.189; +0.514] y $p=0.3627$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Ingreso laboral. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **+0.505 %** en ingreso geométrico condicional entre perceptores positivos, con intervalo [-0.140; +1.155] y $p=0.125$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Desempleo, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.024 pp ($p=0.787$); LLM: -0.005 pp ($p=0.965$); Software: +0.090 pp ($p=0.322$); Robots: +0.046 pp ($p=0.652$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

No cotización, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.038 pp ($p=0.832$); LLM: +0.200 pp ($p=0.3$); Software: +0.035 pp ($p=0.866$); Robots: -0.101 pp ($p=0.574$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Ingreso laboral, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -0.577 % ($p=0.0559$); LLM: +0.504 % ($p=0.157$); Software: -0.852 % ($p=0.0148$); Robots: -0.805 % ($p=0.0272$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

La comparación entre indicadores debe leerse junto con sus definiciones. Una asociación salarial positiva para exposición a tareas cognitivas y una asociación negativa para otra forma de automatización pueden coexistir, porque no representan la misma tecnología ni el mismo conjunto de tareas. El uso de una muestra común

descarta que las diferencias se deban únicamente a cobertura distinta, pero no convierte esas asociaciones en mecanismos causales demostrados.

3.2.3. Dinámica temporal y sensibilidad de asignación ocupacional

La versión dinámica reemplaza la interacción posterior por $I_o^k 1(t = s)$, con $s = 2023, 2024, 2025$ y referencia 2022:

$$Y_{iots} = FE + \rho I_o^k + \sum_{s=2023}^{2025} \beta_{ks} I_o^k 1(t = s) + X'_{it} \theta + \varepsilon_{iots}.$$

Tabla 21: DiD dinámico principal AIOE: contrastes respecto a 2022.

Resultado	Año de contraste	Coef. (EE)	IC 95 %	p	N	G
Desempleo	2023	-0.0029 (0.0132)	[-0.0288; 0.0230]	0.8269	431.601	385
Desempleo	2024	-0.0120 (0.0126)	[-0.0368; 0.0128]	0.3429	431.601	385
Desempleo	2025	0.0047 (0.0111)	[-0.0171; 0.0265]	0.6696	431.601	385
No cotización	2023	0.0180 (0.0182)	[-0.0179; 0.0538]	0.3244	396.064	384
No cotización	2024	0.0114 (0.0205)	[-0.0290; 0.0518]	0.5793	396.064	384
No cotización	2025	0.0196 (0.0245)	[-0.0286; 0.0677]	0.4253	396.064	384
Ingreso laboral	2023	0.0823 (0.0366)	[0.0104; 0.1542]	0.02491	377.991	383
Ingreso laboral	2024	0.0594 (0.0401)	[-0.0193; 0.1382]	0.1387	377.991	383
Ingreso laboral	2025	0.0124 (0.0386)	[-0.0634; 0.0882]	0.7471	377.991	383

Tabla 22: AIOE: prueba conjunta de los tres contrastes posteriores y diferencia 2025–2023.

Resultado	F conjunto	p conjunto	Beta2025–Beta2023	EE diferencia	p diferencia
Desempleo	0.79917	0.49491	0.0076121	0.011014	0.4899
No cotización	0.38862	0.76127	0.0015673	0.022187	0.94372
Ingreso laboral	1.9633	0.11901	-0.069868	0.038266	0.068648

La asociación salarial AIOE positiva de 2023 debe distinguirse del promedio posterior: su significancia aislada no implica una trayectoria creciente ni un efecto sostenido. Las pruebas conjuntas y la diferencia 2025–2023 evalúan restricciones posteriores, no pre-tendencias. Las estimaciones dinámicas de los demás índices se conservan en la salida completa.

Tabla 23: Sensibilidad DiD de desempleo: ocupación buscada para desocupados, en lugar de última ocupación.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	AIOE	0.0024 (0.0121)	[-0.0214; 0.0263]	0.842	437.020	385
Desempleo	Webb–IA	0.0173 (0.0096)	[-0.0015; 0.0361]	0.07158	437.020	385
Desempleo	LLM	0.0074 (0.0134)	[-0.0189; 0.0337]	0.5804	437.020	385
Desempleo	Software	0.0165 (0.0112)	[-0.0056; 0.0385]	0.1436	437.020	385
Desempleo	Robots	0.0007 (0.0118)	[-0.0225; 0.0239]	0.9526	437.020	385

La ocupación buscada puede responder a oportunidades contemporáneas y, por tanto, ser endógena a la búsqueda. También incluye personas sin ocupación previa puntuable y modifica la muestra. Esta sensibilidad cambia simultáneamente la asignación y la población incluida; no se interpreta como una prueba aislada del mecanismo tecnológico ni reemplaza la especificación principal basada en último trabajo.

3.3. Triple diferencia y habilitación

3.3.1. Marco teórico, ecuación y base

La triple diferencia compara si el contraste temporal por exposición difiere entre grupos definidos por un habilitador H . Sobre los mismos microdatos y controles del DiD, se estima

$$Y = FE + X'\theta + \rho I + \delta H + \beta IPost + \zeta IH + \xi PostH + \tau IPostH + \varepsilon.$$

Se incluyen todos los términos inferiores no absorbidos. Cuando H identifica educación universitaria, su nivel queda absorbido por las categorías educativas y se omite su columna redundante, sin retirar los controles educativos. El contraste de exposición posterior es β para $H = 0$ y $\beta + \tau$ para $H = 1$. Su varianza es

$$\text{Var}(\hat{\beta} + \hat{\tau}) = \text{Var}(\hat{\beta}) + \text{Var}(\hat{\tau}) + 2 \text{Cov}(\hat{\beta}, \hat{\tau}).$$

La interacción triple τ mide una diferencia adicional entre grupos, no el contraste total del grupo habilitado. El habilitador TIC combina uso individual de computador e internet del hogar; no mide propiedad de equipos, velocidad de conexión ni uso de IA. Los faltantes sin condición positiva observada se codifican como cero, lo que impide interpretar todo el grupo $H = 0$ como ausencia tecnológica confirmada.

La comparación entre grupos necesita supuestos adicionales de evolución contrafactual. Educación y TIC contemporáneos pueden reflejar selección y ajustes posteriores. La especificación describe diferencias condicionadas y no demuestra que los habilitadores protejan causalmente contra pérdidas laborales.

3.3.2. Resultados e interpretación

Tabla 24: DDD AIOE y TIC: contraste basal, interacción triple y contraste neto del grupo habilitado.

Resultado	Término	Coef. (EE)	IC 95 %	p	N	G
Desempleo	H=0	0.0118 (0.0135)	[-0.0147; 0.0383]	0.3836	431.601	385
Desempleo	H=1	-0.0141 (0.0143)	[-0.0422; 0.0141]	0.3262	431.601	385
Desempleo	Interacción triple	-0.0258 (0.0171)	[-0.0596; 0.0079]	0.1325	431.601	385
No cotización	H=0	0.0331 (0.0206)	[-0.0074; 0.0736]	0.1093	396.064	384
No cotización	H=1	0.0046 (0.0291)	[-0.0527; 0.0619]	0.8743	396.064	384
No cotización	Interacción triple	-0.0285 (0.0280)	[-0.0835; 0.0265]	0.3095	396.064	384
Ingreso laboral	H=0	0.0344 (0.0324)	[-0.0294; 0.0981]	0.29	377.991	383
Ingreso laboral	H=1	0.0599 (0.0496)	[-0.0377; 0.1574]	0.2283	377.991	383
Ingreso laboral	Interacción triple	0.0255 (0.0425)	[-0.0581; 0.1091]	0.5492	377.991	383

Tabla 25: DDD AIOE y educación universitaria: contraste basal, interacción triple y contraste neto.

Resultado	Término	Coef. (EE)	IC 95 %	p	N	G
Desempleo	H=0	0.0055 (0.0137)	[-0.0216; 0.0325]	0.6913	431.601	385
Desempleo	H=1	-0.0318 (0.0260)	[-0.0829; 0.0193]	0.2216	431.601	385
Desempleo	Interacción triple	-0.0373 (0.0297)	[-0.0958; 0.0212]	0.2108	431.601	385
No cotización	H=0	0.0320 (0.0240)	[-0.0151; 0.0792]	0.1822	396.064	384
No cotización	H=1	0.0345 (0.0477)	[-0.0593; 0.1282]	0.47	396.064	384
No cotización	Interacción triple	0.0024 (0.0503)	[-0.0964; 0.1013]	0.9612	396.064	384
Ingreso laboral	H=0	0.0522 (0.0369)	[-0.0204; 0.1249]	0.1581	377.991	383
Ingreso laboral	H=1	0.0139 (0.0940)	[-0.1710; 0.1987]	0.8829	377.991	383
Ingreso laboral	Interacción triple	-0.0384 (0.0923)	[-0.2200; 0.1432]	0.6779	377.991	383

Tabla 25: DDD AIOE y educación universitaria: contraste basal, interacción triple y contraste neto.

Resultado	Término	Coef. (EE)	IC 95 %	p	N	G
-----------	---------	------------	---------	---	---	---

Para **habilitación TIC**, la diferencia adicional entre grupos asociada a 0,1 unidades de AIOE es: desempleo: -0.258 pp, $p=0.133$; no cotización: -0.285 pp, $p=0.309$; ingreso laboral: +0.255 puntos logarítmicos $\times 100$, $p=0.549$. En el resultado salarial, la interacción es una diferencia de cambios logarítmicos, no una suma de porcentajes de ingreso. El contraste neto del grupo habilitado debe leerse en la fila $H=1$.

Para **educación universitaria**, la diferencia adicional entre grupos asociada a 0,1 unidades de AIOE es: desempleo: -0.373 pp, $p=0.211$; no cotización: +0.024 pp, $p=0.961$; ingreso laboral: -0.384 puntos logarítmicos $\times 100$, $p=0.678$. En el resultado salarial, la interacción es una diferencia de cambios logarítmicos, no una suma de porcentajes de ingreso. El contraste neto del grupo habilitado debe leerse en la fila $H=1$.

Ninguna de las interacciones triples principales AIOE es significativa al 5 %. No existe aquí evidencia suficiente para afirmar una diferencia adicional por habilitación con ese criterio; tampoco se demuestra igualdad exacta entre grupos. En términos económicos, la interpretación pertinente es comparar magnitudes e intervalos de β , τ y $\beta + \tau$, no atribuir a TIC o educación una protección validada.

Tabla 26: Interacciones triples de los indicadores complementarios; regresiones separadas sobre la misma muestra de cada resultado.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	TIC / Webb-IA	0.0089 (0.0207)	[-0.0318; 0.0497]	0.6671	431.601	385
Desempleo	TIC / LLM	-0.0260 (0.0182)	[-0.0619; 0.0098]	0.1543	431.601	385
Desempleo	TIC / Software	0.0257 (0.0216)	[-0.0167; 0.0682]	0.2333	431.601	385
Desempleo	TIC / Robots	0.0190 (0.0172)	[-0.0148; 0.0529]	0.2699	431.601	385
No cotización	TIC / Webb-IA	-0.0273 (0.0290)	[-0.0842; 0.0297]	0.3473	396.064	384
No cotización	TIC / LLM	-0.0205 (0.0293)	[-0.0780; 0.0370]	0.4836	396.064	384
No cotización	TIC / Software	0.0154 (0.0293)	[-0.0423; 0.0731]	0.5996	396.064	384
No cotización	TIC / Robots	0.0288 (0.0276)	[-0.0254; 0.0830]	0.2966	396.064	384
Ingreso laboral	TIC / Webb-IA	0.0425 (0.0546)	[-0.0648; 0.1499]	0.4365	377.991	383
Ingreso laboral	TIC / LLM	0.0233 (0.0489)	[-0.0729; 0.1194]	0.6343	377.991	383
Ingreso laboral	TIC / Software	-0.0069 (0.0564)	[-0.1179; 0.1040]	0.9023	377.991	383
Ingreso laboral	TIC / Robots	-0.0337 (0.0502)	[-0.1324; 0.0649]	0.5017	377.991	383
Desempleo	Educación / Webb-IA	-0.0202 (0.0259)	[-0.0711; 0.0306]	0.4346	431.601	385
Desempleo	Educación / LLM	-0.0208 (0.0338)	[-0.0873; 0.0456]	0.5383	431.601	385
Desempleo	Educación / Software	-0.0064 (0.0313)	[-0.0678; 0.0551]	0.8388	431.601	385
Desempleo	Educación / Robots	0.0083 (0.0298)	[-0.0502; 0.0668]	0.7808	431.601	385
No cotización	Educación / Webb-IA	-0.0181 (0.0422)	[-0.1010; 0.0648]	0.6678	396.064	384
No cotización	Educación / LLM	-0.0090 (0.0553)	[-0.1178; 0.0998]	0.8711	396.064	384
No cotización	Educación / Software	0.0144 (0.0471)	[-0.0782; 0.1070]	0.7598	396.064	384
No cotización	Educación / Robots	0.0179 (0.0489)	[-0.0783; 0.1141]	0.714	396.064	384
Ingreso laboral	Educación / Webb-IA	0.0278 (0.0838)	[-0.1370; 0.1926]	0.7406	377.991	383
Ingreso laboral	Educación / LLM	-0.0426 (0.1116)	[-0.2621; 0.1769]	0.703	377.991	383
Ingreso laboral	Educación / Software	-0.0230 (0.0902)	[-0.2004; 0.1544]	0.7989	377.991	383
Ingreso laboral	Educación / Robots	-0.0432 (0.0877)	[-0.2155; 0.1291]	0.6224	377.991	383

Interacción triple: TIC

Desempleo, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.089 pp (p=0.667); LLM: -0.260 pp (p=0.154); Software: +0.257 pp (p=0.233); Robots: +0.190 pp (p=0.27). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

No cotización, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -0.273 pp (p=0.347); LLM: -0.205 pp (p=0.484); Software: +0.154 pp (p=0.6); Robots: +0.288 pp (p=0.297). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Ingreso laboral, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.425 puntos logarítmicos $\times 100$ (p=0.436); LLM: +0.233 puntos logarítmicos $\times 100$ (p=0.634); Software: -0.069 puntos logarítmicos $\times 100$ (p=0.902); Robots: -0.337 puntos logarítmicos $\times 100$ (p=0.502). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Interacción triple: Educación universitaria

Desempleo, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -0.202 pp (p=0.435); LLM: -0.208 pp (p=0.538); Software: -0.064 pp (p=0.839); Robots: +0.083 pp (p=0.781). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

No cotización, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -0.181 pp (p=0.668); LLM: -0.090 pp (p=0.871); Software: +0.144 pp (p=0.76); Robots: +0.179 pp (p=0.714). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Ingreso laboral, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.278 puntos logarítmicos $\times 100$ (p=0.741); LLM: -0.426 puntos logarítmicos $\times 100$ (p=0.703); Software: -0.230 puntos logarítmicos $\times 100$ (p=0.799); Robots: -0.432 puntos logarítmicos $\times 100$ (p=0.622). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Los contrastes complementarios son exploratorios. Su interpretación exige conservar el grupo habilitador, la escala y el resultado correspondiente; un coeficiente triple significativo de un indicador específico no se extiende automáticamente a toda la IA o a ambos habilitadores.

3.4. Exposición territorial tipo shift-share

3.4.1. Marco teórico, ecuación y base

Borusyak et al. (2022) y Goldsmith-Pinkham et al. (2020) explican que la identificación de diseños shift-share depende de la fuente de variación y de sus supuestos de exogeneidad. Aquí se utiliza exposición departamental construida con participaciones ocupacionales de 2022; **la implementación es una regresión ponderada, no variables instrumentales**. No existe una primera etapa que instrumente adopción observada de IA. Se cita esta literatura, formulada originalmente para diseños de variables instrumentales, porque su argumento sobre la exogeneidad de las participaciones (fijas y predeterminadas al periodo de exposición) aplica igual a una construcción shift-share usada como regresor directo; no porque este ejercicio replique su estrategia de identificación instrumental.

La unidad de observación sigue siendo la cohorte departamento-sexo-generación en cada año:

$$\bar{Y}_{ct} = \alpha_c + \lambda_t + \beta_k I_{d(c),2022}^k Post_t + \bar{X}_{ct}'\theta + u_{ct}.$$

Se utilizan hasta 1.320 celdas, efectos fijos de cohorte y año, ponderación por número de receptores PET y errores agrupados por departamento. El índice departamental basal es fijo y su nivel queda absorbido por

los efectos de cohorte. La exposición común dentro de un departamento no crea 330 fuentes territoriales independientes de variación: la inferencia reconoce 33 grupos departamentales.

3.4.2. Resultados e interpretación

Tabla 27: Exposición departamental basal: resultados estáticos sobre cohortes, con errores agrupados por departamento.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	AIOE	0.0691 (0.0780)	[-0.0898; 0.2280]	0.3825	1.320	33
Desempleo	Webb-IA	-0.0414 (0.0893)	[-0.2234; 0.1406]	0.6462	1.320	33
Desempleo	LLM	0.0792 (0.0777)	[-0.0790; 0.2374]	0.3155	1.320	33
Desempleo	Software	-0.0568 (0.0871)	[-0.2342; 0.1207]	0.5195	1.320	33
Desempleo	Robots	-0.0766 (0.0733)	[-0.2259; 0.0726]	0.3033	1.320	33
No cotización	AIOE	-0.0552 (0.0918)	[-0.2422; 0.1318]	0.5516	1.320	33
No cotización	Webb-IA	0.2098 (0.0901)	[0.0264; 0.3933]	0.02629	1.320	33
No cotización	LLM	0.0050 (0.1040)	[-0.2069; 0.2168]	0.9623	1.320	33
No cotización	Software	0.1596 (0.0801)	[-0.0037; 0.3228]	0.0551	1.320	33
No cotización	Robots	0.0418 (0.0846)	[-0.1306; 0.2141]	0.6251	1.320	33
Ingreso laboral	AIOE	0.2713 (0.1831)	[-0.1017; 0.6444]	0.1482	1.320	33
Ingreso laboral	Webb-IA	-0.3025 (0.1831)	[-0.6755; 0.0706]	0.1084	1.320	33
Ingreso laboral	LLM	0.2718 (0.2177)	[-0.1716; 0.7153]	0.2208	1.320	33
Ingreso laboral	Software	-0.2973 (0.1849)	[-0.6740; 0.0795]	0.1178	1.320	33
Ingreso laboral	Robots	-0.2775 (0.1888)	[-0.6622; 0.1071]	0.1514	1.320	33

Desempleo. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **+0.691 puntos porcentuales** en tasa de desempleo de cohorte, con intervalo [-0.898; +2.280] y $p=0.3825$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

No cotización. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **-0.552 puntos porcentuales** en no cotización pensional, con intervalo [-2.422; +1.318] y $p=0.5516$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Ingreso laboral. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **+2.751 %** en ingreso laboral medio positivo de cohorte, con intervalo [-1.012; +6.656] y $p=0.1482$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Desempleo, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -0.414 pp ($p=0.646$); LLM: +0.792 pp ($p=0.316$); Software: -0.568 pp ($p=0.519$); Robots: -0.766 pp ($p=0.303$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

No cotización, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +2.098 pp ($p=0.0263$); LLM: +0.050 pp ($p=0.962$); Software: +1.596 pp ($p=0.0551$); Robots: +0.418 pp ($p=0.625$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Ingreso laboral, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -2.980 % ($p=0.108$); LLM: +2.756 % ($p=0.221$); Software: -2.929 % ($p=0.118$); Robots: -2.737 % ($p=0.151$). Los intervalos

de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Las asociaciones territoriales pueden recoger estructura productiva, urbanización y shocks simultáneos. Fijar las participaciones en 2022 evita actualizarlas mecánicamente con el resultado posterior, pero no prueba que sean exógenas. Los coeficientes de una media de cohorte no equivalen a efectos individuales sobre personas con la misma exposición.

Tabla 28: Dinámica AIOE de exposición departamental: contrastes con 2022.

Resultado	Año de contraste	Coef. (EE)	IC 95 %	p	N	G
Desempleo	2023	0.0089 (0.0992)	[-0.1931; 0.2109]	0.9291	1.320	33
Desempleo	2024	0.1184 (0.1053)	[-0.0961; 0.3329]	0.2692	1.320	33
Desempleo	2025	0.0824 (0.0712)	[-0.0627; 0.2274]	0.2559	1.320	33
No cotización	2023	-0.1467 (0.0673)	[-0.2838; -0.0096]	0.03671	1.320	33
No cotización	2024	-0.1013 (0.1745)	[-0.4566; 0.2541]	0.5656	1.320	33
No cotización	2025	0.0813 (0.0773)	[-0.0762; 0.2387]	0.301	1.320	33
Ingreso laboral	2023	0.4995 (0.2388)	[0.0130; 0.9859]	0.0445	1.320	33
Ingreso laboral	2024	0.4283 (0.2346)	[-0.0496; 0.9062]	0.07726	1.320	33
Ingreso laboral	2025	-0.1096 (0.2314)	[-0.5810; 0.3617]	0.6389	1.320	33

Las asociaciones de 2023 no implican persistencia hasta 2025. Deben leerse con los intervalos de cada año y el resultado estático, especialmente porque se exploran varios resultados y periodos con solo 33 grupos de inferencia.

3.5. Efectos fijos de cohorte y primeras diferencias

3.5.1. Marco teórico, ecuaciones y bases

El modelo Within utiliza exposición basal propia de cada cohorte, en lugar de la exposición común departamental:

$$\bar{Y}_{ct} = \alpha_c + \lambda_t + \beta_k I_{c,2022}^k Post_t + \bar{X}_{ct}'\theta + u_{ct}.$$

Los efectos de cohorte absorben diferencias invariantes entre grupos. La exposición puede variar entre sexos y generaciones de un mismo departamento porque sus composiciones ocupacionales basales difieren. Se pondera por receptores PET y se agrupan errores por departamento. Wooldridge (2010) proporciona el marco de efectos fijos y transformaciones temporales; su aplicación al pseudo-panel debe incorporar las advertencias de composición y error de medición de Verbeek (2008).

La diferencia larga compara 2025 con 2022:

$$\bar{Y}_{c,2025} - \bar{Y}_{c,2022} = a + \beta_k I_{c,2022}^k + (\bar{X}_{c,2025} - \bar{X}_{c,2022})'\theta + \Delta u_c.$$

Se usan 330 diferencias de cohorte y el promedio de tamaños PET de ambos extremos como ponderador. No son diferencias consecutivas acumuladas. Within resume el contraste posterior durante tres años, mientras que la diferencia larga compara dos extremos; diferencias entre estimadores pueden reflejar temporalidad y composición, además de especificación.

3.5.2. Resultados e interpretación

Tabla 29: Within de cohortes: exposición propia de 2022, índices separados.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	AIOE	-0.0507 (0.0384)	[-0.1288; 0.0275]	0.1959	1.320	33
Desempleo	Webb-IA	0.0504 (0.0184)	[0.0129; 0.0879]	0.00995	1.320	33
Desempleo	LLM	-0.0274 (0.0517)	[-0.1326; 0.0779]	0.6001	1.320	33
Desempleo	Software	0.0585 (0.0173)	[0.0233; 0.0938]	0.001911	1.320	33
Desempleo	Robots	0.0633 (0.0356)	[-0.0092; 0.1358]	0.08501	1.320	33
No cotización	AIOE	0.0192 (0.0558)	[-0.0945; 0.1329]	0.7329	1.320	33
No cotización	Webb-IA	0.0725 (0.0314)	[0.0085; 0.1364]	0.02754	1.320	33
No cotización	LLM	0.0135 (0.0738)	[-0.1369; 0.1638]	0.8565	1.320	33
No cotización	Software	0.0535 (0.0304)	[-0.0086; 0.1155]	0.08877	1.320	33
No cotización	Robots	0.0067 (0.0465)	[-0.0881; 0.1014]	0.8871	1.320	33
Ingreso laboral	AIOE	-0.0649 (0.1311)	[-0.3320; 0.2022]	0.6242	1.320	33
Ingreso laboral	Webb-IA	-0.1705 (0.0808)	[-0.3351; -0.0059]	0.04275	1.320	33
Ingreso laboral	LLM	-0.0844 (0.2256)	[-0.5439; 0.3751]	0.7107	1.320	33
Ingreso laboral	Software	-0.1136 (0.0825)	[-0.2816; 0.0545]	0.1782	1.320	33
Ingreso laboral	Robots	-0.0031 (0.1177)	[-0.2428; 0.2366]	0.9791	1.320	33

Desempleo. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **-0.507 puntos porcentuales** en tasa de desempleo de cohorte, con intervalo [-1.288; +0.275] y $p=0.1959$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

No cotización. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **+0.192 puntos porcentuales** en no cotización pensional, con intervalo [-0.945; +1.329] y $p=0.7329$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Ingreso laboral. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **-0.647 %** en ingreso laboral medio positivo de cohorte, con intervalo [-3.265; +2.043] y $p=0.6242$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Desempleo, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.504 pp ($p=0.00995$); LLM: -0.274 pp ($p=0.6$); Software: +0.585 pp ($p=0.00191$); Robots: +0.633 pp ($p=0.085$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

No cotización, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: +0.725 pp ($p=0.0275$); LLM: +0.135 pp ($p=0.857$); Software: +0.535 pp ($p=0.0888$); Robots: +0.067 pp ($p=0.887$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Ingreso laboral, comparación de indicadores. Para un contraste de 0,1 unidades, Webb-IA: -1.691 % ($p=0.0427$); LLM: -0.840 % ($p=0.711$); Software: -1.129 % ($p=0.178$); Robots: -0.031 % ($p=0.979$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Tabla 30: Diferencias 2025–2022: exposición basal propia de cada cohorte.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	AIOE	-0.0849 (0.0335)	[-0.1532; -0.0166]	0.01646	330	33
Desempleo	Webb–IA	0.0743 (0.0198)	[0.0339; 0.1147]	0.0007104	330	33
Desempleo	LLM	-0.0735 (0.0461)	[-0.1674; 0.0205]	0.1212	330	33
Desempleo	Software	0.0842 (0.0182)	[0.0472; 0.1212]	5.707e-05	330	33
Desempleo	Robots	0.0971 (0.0315)	[0.0329; 0.1613]	0.004227	330	33
No cotización	AIOE	0.0188 (0.0539)	[-0.0909; 0.1285]	0.7296	330	33
No cotización	Webb–IA	0.0770 (0.0312)	[0.0134; 0.1406]	0.01919	330	33
No cotización	LLM	0.0035 (0.0791)	[-0.1576; 0.1646]	0.9651	330	33
No cotización	Software	0.0648 (0.0288)	[0.0061; 0.1235]	0.03167	330	33
No cotización	Robots	0.0218 (0.0430)	[-0.0657; 0.1093]	0.6156	330	33
Ingreso laboral	AIOE	-0.1362 (0.1175)	[-0.3755; 0.1031]	0.2548	330	33
Ingreso laboral	Webb–IA	-0.1984 (0.0831)	[-0.3675; -0.0292]	0.02301	330	33
Ingreso laboral	LLM	-0.2019 (0.2183)	[-0.6466; 0.2428]	0.362	330	33
Ingreso laboral	Software	-0.1460 (0.0784)	[-0.3057; 0.0136]	0.07165	330	33
Ingreso laboral	Robots	0.0113 (0.0926)	[-0.1773; 0.1998]	0.9037	330	33

Desempleo. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **-0.849 puntos porcentuales** en tasa de desempleo de cohorte, con intervalo [-1.532; -0.166] y $p=0.01646$. Económicamente, el intervalo excluye cero al 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

No cotización. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **+0.188 puntos porcentuales** en no cotización pensional, con intervalo [-0.909; +1.285] y $p=0.7296$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Ingreso laboral. Un contraste de 0,1 unidades de AIOE se asocia con un cambio diferencial de **-1.353 %** en ingreso laboral medio positivo de cohorte, con intervalo [-3.686; +1.036] y $p=0.2548$. Económicamente, el intervalo incluye cero y no permite establecer un signo con el criterio del 5 %. Esta magnitud corresponde a la especificación y población de la tabla; no se interpreta como respuesta a un aumento observado de adopción de IA.

Desempleo, comparación de indicadores. Para un contraste de 0,1 unidades, Webb–IA: +0.743 pp ($p=0.00071$); LLM: -0.735 pp ($p=0.121$); Software: +0.842 pp ($p=5.71e-05$); Robots: +0.971 pp ($p=0.00423$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

No cotización, comparación de indicadores. Para un contraste de 0,1 unidades, Webb–IA: +0.770 pp ($p=0.0192$); LLM: +0.035 pp ($p=0.965$); Software: +0.648 pp ($p=0.0317$); Robots: +0.218 pp ($p=0.616$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

Ingreso laboral, comparación de indicadores. Para un contraste de 0,1 unidades, Webb–IA: -1.964 % ($p=0.023$); LLM: -1.999 % ($p=0.362$); Software: -1.450 % ($p=0.0717$); Robots: +0.113 % ($p=0.904$). Los intervalos de la tabla determinan la precisión de cada asociación; los valores p son nominales y estas comparaciones no se seleccionan como efectos causales.

La asociación negativa AIOE con desempleo en diferencias largas no alcanza la misma precisión estadística en Within. La conclusión es sensible a la comparación temporal y no debe formularse como un efecto estable demostrado. La diferencia entre estimadores no es una prueba de Wooldridge; el R^2 general de una regresión con efectos fijos tampoco se denomina R^2 Within.

3.6. Sensibilidad de escala y trazabilidad

La comparación principal conserva cinco índices separados en escala percentil. Las versiones Min–Max y la envolvente máxima se mantienen como sensibilidad de medición, no como candidatas entre las que escoger el menor valor p. Sus coeficientes no son directamente comparables en magnitud a los percentiles, aunque ambos rangos estén acotados entre cero y uno.

Tabla 31: Sensibilidad DiD estática: Min–Max y envolvente máxima.

Resultado	Índice	Coef. (EE)	IC 95 %	p	N	G
Desempleo	Envolvente	-0.0020 (0.0118)	[-0.0253; 0.0213]	0.8649	431.601	385
Desempleo	AIOE MM	-0.0044 (0.0118)	[-0.0277; 0.0189]	0.7103	431.601	385
Desempleo	Webb–IA MM	0.0004 (0.0139)	[-0.0269; 0.0278]	0.9747	431.601	385
Desempleo	LLM MM	-0.0024 (0.0167)	[-0.0351; 0.0304]	0.887	431.601	385
Desempleo	Software MM	0.0194 (0.0185)	[-0.0169; 0.0558]	0.2938	431.601	385
Desempleo	Robots MM	0.0034 (0.0155)	[-0.0271; 0.0339]	0.8275	431.601	385
Desempleo	Envolvente MM	-0.0063 (0.0132)	[-0.0322; 0.0197]	0.6361	431.601	385
No cotización	Envolvente	0.0296 (0.0193)	[-0.0083; 0.0676]	0.1258	396.064	384
No cotización	AIOE MM	0.0166 (0.0197)	[-0.0222; 0.0554]	0.4005	396.064	384
No cotización	Webb–IA MM	0.0110 (0.0295)	[-0.0470; 0.0691]	0.7088	396.064	384
No cotización	LLM MM	0.0315 (0.0259)	[-0.0195; 0.0825]	0.2248	396.064	384
No cotización	Software MM	0.0437 (0.0428)	[-0.0404; 0.1278]	0.3071	396.064	384
No cotización	Robots MM	-0.0346 (0.0237)	[-0.0813; 0.0121]	0.1455	396.064	384
No cotización	Envolvente MM	0.0268 (0.0225)	[-0.0174; 0.0710]	0.2334	396.064	384
Ingreso laboral	Envolvente	-0.0333 (0.0324)	[-0.0969; 0.0304]	0.3052	377.991	383
Ingreso laboral	AIOE MM	0.0558 (0.0355)	[-0.0140; 0.1257]	0.1169	377.991	383
Ingreso laboral	Webb–IA MM	-0.1277 (0.0559)	[-0.2376; -0.0178]	0.02283	377.991	383
Ingreso laboral	LLM MM	0.0683 (0.0481)	[-0.0264; 0.1629]	0.1569	377.991	383
Ingreso laboral	Software MM	-0.2233 (0.1024)	[-0.4246; -0.0221]	0.02973	377.991	383
Ingreso laboral	Robots MM	-0.0700 (0.0588)	[-0.1856; 0.0456]	0.2345	377.991	383
Ingreso laboral	Envolvente MM	0.0230 (0.0403)	[-0.0562; 0.1022]	0.5685	377.991	383

El [archivo completo de resultados comparables](#) conserva todas las familias, niveles basales, interacciones, componentes, escalas, muestras y fuentes. Las salidas anteriores centradas en la envolvente permanecen identificadas como históricas; no se mezclan con las tablas de esta estrategia. Las especificaciones AIOE principales se contrastan con Stata y las comprobaciones se registran junto a los resultados.

4. Aprendizaje automático: DML y R-learner

4.1. Fundamento, bases y organización de la evaluación

Chernozhukov et al. (2018) desarrollan procedimientos de estimación con funciones auxiliares aprendidas de forma flexible, puntuaciones ortogonales y particiones de muestra. Estos recursos reducen determinados sesgos de regularización y reutilización de observaciones bajo condiciones de identificación; no sustituyen esas condiciones. Nie & Wager (2021) proponen un criterio residualizado para aprender heterogeneidad mediante funciones flexibles. La implementación utiliza `HistGradientBoostingRegressor`; no se denomina bosque causal generalizado a un algoritmo de boosting.

Se emplean microdatos integrados, ocupación actual o previa según situación laboral, educación válida, factores de expansión y cobertura común de los cinco índices. AIOE es principal; Webb–IA y LLM son alternativas;

software, robots, Min–Max y envolvente se conservan como extensiones diagnósticas. Los controles incluyen exposición basal, año, departamento, ocupación agregada, educación y características individuales; las variables categóricas se codifican como tales.

Las particiones externas agrupan ocupaciones de cuatro dígitos para impedir que una misma ocupación aparezca simultáneamente en entrenamiento y evaluación. Se utilizan cinco particiones externas. Para R-learner, las funciones auxiliares del entrenamiento externo se obtienen mediante tres particiones internas. Las respuestas de la muestra externa no intervienen en el ajuste que genera su predicción. Se utilizan pesos tanto en el entrenamiento como en la evaluación y la inferencia agrupada.

4.2. DML/PLR: ecuación, resultados y diagnóstico

El modelo parcialmente lineal plantea

$$Y = \theta D + g(X) + \varepsilon, \quad D = m(X) + v, \quad D = I^k Post.$$

Con predicciones externas $\hat{\ell}(X)$ y $\hat{m}(X)$, se construyen $\tilde{Y} = Y - \hat{\ell}(X)$ y $\tilde{D} = D - \hat{m}(X)$, y se obtiene

$$\hat{\theta} = \frac{\sum_i w_i \tilde{D}_i \tilde{Y}_i}{\sum_i w_i \tilde{D}_i^2}.$$

En el diseño concreto, I^k y el año están incluidos en X , de modo que D es determinista condicionado a esos controles:

$$\text{Var}(D \mid X) = 0.$$

Por tanto, no existe la variación residual identificadora habitual del PLR. El denominador positivo que produce un aprendiz imperfecto refleja error predictivo del tratamiento, no variación exógena. Las estimaciones se presentan para diagnosticar este comportamiento y comparar sensibilidades computacionales; **no son efectos causales identificados**.

Tabla 32: PLR con índices separados: coeficientes diagnósticos, sin interpretación causal.

Resultado	Índice	PLR (EE)	IC 95 %	p diagnóstico	N	G
Desempleo	AIOE	-0.6046 (0.4519)	[-1.493; 0.284]	0.18176	431.601	385
Desempleo	Webb–IA	-0.5304 (0.7627)	[-2.030; 0.969]	0.48723	431.601	385
Desempleo	LLM	-0.6227 (0.5616)	[-1.727; 0.482]	0.26823	431.601	385
Desempleo	Software	-0.6967 (0.4066)	[-1.496; 0.103]	0.087418	431.601	385
Desempleo	Robots	-0.4349 (0.5387)	[-1.494; 0.624]	0.42	431.601	385
No cotización	AIOE	-6.8258 (3.9960)	[-14.683; 1.031]	0.088421	396.064	384
No cotización	Webb–IA	-1.2616 (2.3744)	[-5.930; 3.407]	0.5955	396.064	384
No cotización	LLM	0.3710 (2.3092)	[-4.169; 4.911]	0.87245	396.064	384
No cotización	Software	-4.7070 (2.1560)	[-8.946; -0.468]	0.029626	396.064	384
No cotización	Robots	-4.8088 (2.2228)	[-9.179; -0.438]	0.031131	396.064	384
Ingreso laboral	AIOE	4.0985 (2.6253)	[-1.063; 9.260]	0.11932	377.991	383
Ingreso laboral	Webb–IA	4.8788 (2.4631)	[0.036; 9.722]	0.048337	377.991	383
Ingreso laboral	LLM	-1.6660 (2.6216)	[-6.821; 3.489]	0.52549	377.991	383
Ingreso laboral	Software	-2.5706 (2.7774)	[-8.032; 2.890]	0.35527	377.991	383
Ingreso laboral	Robots	1.6679 (4.1274)	[-6.447; 9.783]	0.68637	377.991	383

Los valores p e intervalos describen la variación del estimador calculado bajo su procedimiento. Incluso si alguno excluye cero, no validan el parámetro causal cuando falla la identificación. Coeficientes de gran magnitud pueden

resultar de un denominador residual pequeño y no deben convertirse en trabajadores afectados, probabilidades de desempleo o ganancias salariales atribuibles a IA.

4.3. R-learner: heterogeneidad y evaluación externa

R-learner busca una función $\tau(X)$ mediante

$$\hat{\tau} = \arg \min_{\tau \in \mathcal{T}} \sum_i w_i \{\tilde{Y}_i - \tau(X_i) \tilde{D}_i\}^2 + \mathcal{P}(\tau).$$

En la implementación, la complejidad se controla mediante la configuración del boosting. La forma de respuesta residualizada utiliza ponderaciones proporcionales a $w_i \tilde{D}_i^2$ y conserva observaciones con $|\tilde{D}| > 10^{-4}$ en el ajuste de la función de heterogeneidad. Las predicciones de heterogeneidad se generan fuera de la partición externa correspondiente. La evaluación anidada se realiza para AIOE, Webb-IA y LLM en los tres resultados; las extensiones de software, robots y otras escalas se mantienen como diagnósticos PLR.

La calibración externa BLP relaciona el resultado residual con el tratamiento residual y la señal de heterogeneidad predicha. Su pendiente permite describir si esa señal aporta una relación residual fuera del entrenamiento. Una pendiente significativa no prueba heterogeneidad causal; la misma falta de variación condicional del tratamiento limita su interpretación económica.

Tabla 33: R-learner de los tres índices de IA: calibración externa y segundo momento del tratamiento residual.

Resultado	Índice	Media D residual ²	Var D	BLP (EE)	p BLP
Desempleo	AIOE	5.1763e-05	0.098925	-0.0012 (0.0492)	0.98045
Desempleo	Webb-IA	4.9997e-05	0.1005	0.0628 (0.0603)	0.29858
Desempleo	LLM	5.0969e-05	0.093946	-0.0054 (0.0877)	0.95062
No cotización	AIOE	4.3803e-05	0.098875	0.0207 (0.1033)	0.84113
No cotización	Webb-IA	4.8206e-05	0.10238	-0.0480 (0.0423)	0.25691
No cotización	LLM	6.2794e-05	0.093395	-0.0062 (0.0317)	0.84595
Ingreso laboral	AIOE	5.0732e-05	0.099367	-0.0052 (0.1003)	0.95851
Ingreso laboral	Webb-IA	8.6967e-05	0.10052	0.0948 (0.1066)	0.37446
Ingreso laboral	LLM	4.7109e-05	0.093889	-0.0577 (0.0623)	0.35491

Desempleo. El coeficiente PLR diagnóstico es -0.6046, p=0.1818. La calibración externa BLP no presenta pendiente distinta de cero al 5 % (pendiente -0.0012, p=0.9804). El segundo momento ponderado del tratamiento residual equivale a 0.052 % de la varianza total de D. Estos resultados describen el comportamiento del aprendizaje y de su residualización; no permiten calcular creación de empleo, formalización o ganancias salariales causadas por IA.

No cotización. El coeficiente PLR diagnóstico es -6.8258, p=0.08842. La calibración externa BLP no presenta pendiente distinta de cero al 5 % (pendiente +0.0207, p=0.8411). El segundo momento ponderado del tratamiento residual equivale a 0.044 % de la varianza total de D. Estos resultados describen el comportamiento del aprendizaje y de su residualización; no permiten calcular creación de empleo, formalización o ganancias salariales causadas por IA.

Ingreso laboral. El coeficiente PLR diagnóstico es +4.0985, p=0.1193. La calibración externa BLP no presenta pendiente distinta de cero al 5 % (pendiente -0.0052, p=0.9585). El segundo momento ponderado del tratamiento residual equivale a 0.051 % de la varianza total de D. Estos resultados describen el comportamiento del aprendizaje y de su residualización; no permiten calcular creación de empleo, formalización o ganancias salariales causadas por IA.

La conclusión económica de este bloque es una delimitación del alcance: los procedimientos pueden revelar diferencias de ajuste y de señal residual, pero no identifican cuánto cambiaría el empleo o el ingreso si aumentara la adopción de IA. Para esa pregunta se necesita variación de tratamiento no determinada por los controles y

un diseño que justifique su exogeneidad. Los escenarios siguientes utilizan coeficientes de la especificación DiD predefinida, no estos coeficientes ML.

5. Escenarios condicionales para 2026–2030

5.1. Marco de proyección, fuentes y supuestos

Los escenarios exploran qué implicaría prolongar determinadas asociaciones bajo trayectorias explícitas. No constituyen pronósticos validados de adopción ni efectos causales identificados. Se fija AIOE percentil como referencia para desempleo, no cotización e ingreso; Webb–IA y LLM son alternativas separadas. Los coeficientes provienen del **DiD individual estático con los mismos controles y muestra común por resultado**, de modo que las comparaciones no combinan estimadores territoriales, escalas distintas o parámetros seleccionados por significancia.

La cadena de calibración registra índice, normalización, agregación, archivo, celda y huella SHA-256 del coeficiente. El término de exposición se aplica con su signo estimado. Las alternativas no se suman: comparten tareas y representan métricas diferentes. Software y robots se presentan en las estimaciones históricas, pero no se extrapolan aquí porque no se ha calibrado una trayectoria específica de difusión de esas tecnologías.

Se distinguen dos ejercicios. La microsimulación salarial aplica una trayectoria logística supuesta a ocupados de 2025. El ejercicio departamental aplica un multiplicador de habilitación tecnológica a la exposición de 2022 para los tres resultados. Sus niveles, referencias y escalas temporales son diferentes; no son dos cálculos de un mismo pronóstico y no deben mezclarse.

5.2. Microsimulación salarial con AIOE

5.2.1. Ecuaciones y base

Para cada escenario s , la trayectoria es

$$A_s(t) = \frac{A_{max,s}}{1 + \exp\{-\lambda_s(t - t_{0,s})\}}.$$

Los parámetros son supuestos de escenario. Se calculan todos los valores anuales desde la fórmula; no se sustituyen por una tabla manual de adopción.

Tabla 34: Parámetros supuestos de las trayectorias logísticas.

Escenario	A_max	Velocidad	Punto medio
Conservador	0.3	0.4	2023.5
Base	0.5	0.65	2024.0
Acelerado	0.75	0.9	2024.5

La base salarial utiliza ocupados de 2025 con ingreso positivo, los cinco índices disponibles, educación válida y ocupación actual identificable. La muestra reproduce los requisitos del DiD salarial para ese año. El ingreso de la ECV integrada es imputado desde GEIH, no observado directamente en la persona receptora. La composición y las ponderaciones se mantienen fijas. Se aplica

$$\log w_{i,t}^{real} = \log w_{i,2025}^{real} + g(t - 2025) + \hat{\beta}_{sal}^{AIOE} I_i^{AIOE} \{A_s(t) - A_s(2025)\}, \quad g = 0.015.$$

La tasa de crecimiento es continua y supuesta. El escenario $\beta = 0$ conserva exactamente el mismo crecimiento y elimina solo el término asociado a exposición. No se modelan entrada al empleo, desempleo, cambio de

ocupación, negociación salarial ni cambios demográficos. La extrapolación presupone estabilidad del coeficiente fuera del periodo de estimación.

Los intervalos se calculan sustituyendo $\hat{\beta}$ por los extremos de su intervalo de confianza, manteniendo las demás condiciones. Son bandas **condicionadas a la calibración**, no intervalos predictivos completos: excluyen incertidumbre de difusión, crecimiento, composición, correspondencias ocupacionales y emparejamiento.

5.2.2. Resultados e interpretación económica

La base de escenario contiene **102.492 ocupados** y **98.384 perceptores con ingreso positivo**. El segundo grupo determina las medias salariales; el primero se utiliza para el índice ilustrativo.

Tabla 35: Ingreso laboral medio simulado, COP de octubre de 2025: años seleccionados y referencia sin término de exposición.

Año	Escenario	Ingreso COP	IC inferior	IC superior	Beta=0
2025	Conservador	1.939.182	1.939.182	1.939.182	1.939.182
2026	Conservador	1.969.893	1.968.098	1.971.689	1.968.489
2028	Conservador	2.032.039	2.027.436	2.036.657	2.028.439
2030	Conservador	2.095.196	2.088.827	2.101.590	2.090.214
2025	Base	1.939.182	1.939.182	1.939.182	1.939.182
2026	Base	1.972.020	1.967.506	1.976.548	1.968.489
2028	Base	2.036.183	2.026.286	2.046.145	2.028.439
2030	Base	2.099.635	2.087.596	2.111.766	2.090.214
2025	Acelerado	1.939.182	1.939.182	1.939.182	1.939.182
2026	Acelerado	1.976.043	1.966.389	1.985.759	1.968.489
2028	Acelerado	2.043.246	2.024.334	2.062.391	2.028.439
2030	Acelerado	2.106.972	2.085.572	2.128.663	2.090.214




Figura 3: Escenarios salariales AIOE por grupos de exposición, con bandas condicionadas al coeficiente y referencia beta=0.

El coeficiente salarial principal AIOE es positivo, pero su intervalo incluye cero. Por eso la trayectoria puntual puede superar la referencia sin término de exposición sin establecer una ganancia causal o un signo estadísticamente determinado. El aumento del ingreso entre 2025 y 2030 combina el crecimiento exógeno supuesto con el término de exposición; no debe atribuirse íntegramente a IA. Las diferencias iniciales entre ocupaciones también contribuyen a las brechas futuras.

5.3. Escenarios departamentales de desempleo, no cotización e ingreso

5.3.1. Ecuaciones y bases

La trayectoria auxiliar parte del indicador observado de uso individual de computador y acceso a internet del hogar entre 2022 y 2025. Se calcula su tasa anual compuesta y se aplican factores 0,5, 1 y 1,5 para los escenarios lento, base y rápido, acotando las prevalencias entre cero y uno. Los valores ausentes sin condición positiva observada se codifican como cero; la serie no mide adopción de IA y cuatro años no validan una trayectoria tecnológica de largo plazo.

Sean $H_s(t)$ la trayectoria de habilitación y $m_s(t) = H_s(t)/H(2025)$. Para cada índice k se utiliza la exposición departamental de ocupados de 2022 con cobertura común:

$$\Delta y_{d,t,s}^k = \hat{\beta}_y^k I_{d,2022}^k \{m_s(t) - 1\}.$$

Para desempleo y no cotización se reporta $100\Delta y$ en puntos porcentuales. Para ingreso se reporta $100[\exp(\Delta \log w) - 1]$ en porcentaje. Se extrapola un coeficiente individual mediante una media territorial de exposición; esta transferencia es un supuesto adicional, no una estimación causal departamental. El escenario $\beta=0$ produce cambio nulo en este término, sin representar la evolución completa de la tasa laboral.

5.3.2. Resultados principales AIOE

Tabla 36: AIOE, año 2030: media simple de cambios departamentales e intervalos condicionados.

Resultado	Escenario	Cambio	IC inferior	IC superior	Unidad
Desempleo	base	-0.034513	-0.24587	0.17685	pp
Desempleo	lento	-0.016449	-0.11718	0.084285	pp
Desempleo	rapido	-0.054309	-0.38691	0.27829	pp
No cotización	base	0.16477	-0.19069	0.52023	pp
No cotización	lento	0.078528	-0.090879	0.24794	pp
No cotización	rapido	0.25928	-0.30006	0.81862	pp
Ingreso laboral	base	0.51109	-0.14206	1.1686	%
Ingreso laboral	lento	0.24325	-0.06773	0.55521	%
Ingreso laboral	rapido	0.80544	-0.22345	1.8451	%

Para **desempleo**, el escenario base AIOE de 2030 produce una media departamental de -0.035 pp, con intervalo condicionado [-0.246; +0.177]. Este intervalo incluye cero; la magnitud depende de la trayectoria impuesta y de extrapolar la asociación estimada.

Para **no cotización**, el escenario base AIOE de 2030 produce una media departamental de +0.165 pp, con intervalo condicionado [-0.191; +0.520]. Este intervalo incluye cero; la magnitud depende de la trayectoria impuesta y de extrapolar la asociación estimada.

Para **ingreso laboral**, el escenario base AIOE de 2030 produce una media departamental de +0.511 %, con intervalo condicionado [-0.142; +1.169]. Este intervalo incluye cero; la magnitud depende de la trayectoria impuesta y de extrapolar la asociación estimada.

Cada departamento recibe el mismo peso en estas medias. No son agregados nacionales ponderados por población ni cambios observados. La interpretación económica se limita al componente asociado a la exposición bajo la trayectoria asumida. Un intervalo que incluye cero conserva escenarios de signo contrario aun cuando el valor puntual sugiera una mejora o un deterioro.

5.3.3. Comparación con Webb-IA y LLM

Tabla 37: Escenario base de 2030: AIOE y alternativas específicas con la misma especificación DiD de origen.

Resultado	Índice	Cambio	IC inferior	IC superior	Unidad
Desempleo	AIOE	-0.034513	-0.24587	0.17685	pp
No cotización	AIOE	0.16477	-0.19069	0.52023	pp
Ingreso laboral	AIOE	0.51109	-0.14206	1.1686	%
Desempleo	LLM	-0.0054851	-0.25335	0.24238	pp
No cotización	LLM	0.20994	-0.18747	0.60735	pp
Ingreso laboral	LLM	0.53021	-0.20353	1.2694	%
Desempleo	Webb-IA	0.026747	-0.16754	0.22104	pp
No cotización	Webb-IA	0.043059	-0.35595	0.44206	pp
Ingreso laboral	Webb-IA	-0.64716	-1.3062	0.016364	%

Las diferencias entre AIOE, Webb-IA y LLM reflejan simultáneamente sus puntuaciones y sus asociaciones históricas estimadas. La normalización común permite explicitar un contraste de escala, pero no convierte los ejercicios en componentes aditivos de un efecto total. Los archivos completos contienen todos los departamentos, años, escenarios, intervalos y referencias sin término de exposición.

5.4. Indicadores ilustrativos y límites del ejercicio

La participación salarial en el producto es una identidad contable de escenario: parte de 0,495, supuesto inicial, combina la masa salarial simulada con un producto que crece a tasa continua 0,028 y mantiene la composición laboral fija. No es una participación estimada de cuentas nacionales ni el resultado de un equilibrio estructural. El Gini se refiere a ingresos laborales positivos de la muestra simulada, no al ingreso total de todos los hogares.

El índice ilustrativo de reasignación utiliza

$$R_{i,t,s} = \text{logit}^{-1}\{-3.2 + 2.8I_i^{AIOE}(1 - H_i)[A_s(t) - A_s(2025)]\}.$$

Los parámetros no se estiman como probabilidades de desplazamiento. El promedio ponderado multiplicado por 100 es un índice, distinto de la proporción de personas cuyo valor individual supera 25/100. Se calcula entre ocupados de la base de escenario con exposición disponible, incluidos quienes no tienen ingreso positivo; su universo no es el mismo que el salarial.

Tabla 38: Índice ilustrativo y participación salarial contable, año 2030.

Escenario	Índice medio /100	Máximo /100	Proporción >25 (%)	Participación salarial %
Conservador	4.1217	4.9246	0	46.50
Base	4.3252	6.0223	0	46.59
Acelerado	4.7103	8.3393	0	46.76

La ausencia de observaciones por encima del umbral ilustrativo no acredita ausencia de riesgos reales. La diferencia impuesta por TIC en la fórmula tampoco estima una protección causal de internet o del computador. Los rankings ocupacionales exigen al menos 30 observaciones, no 30 personas expandidas; ese umbral es un filtro descriptivo, no garantía de precisión.

6. Síntesis, limitaciones y reproducción

La integración ofrece una base reproducible para estudiar asociaciones entre condiciones laborales, bienestar y exposición tecnológica. La evaluación muestra coherencia de restricciones contables y similitud de determinadas distribuciones, junto con discrepancias individuales y dependencia de donantes. El pseudo-panel permite seguir medias de grupos, pero no elimina cambios de composición ni convierte la integración estadística en seguimiento individual.

La estrategia econométrica principal mantiene AIOE para los tres resultados y conserva los demás indicadores como contrastes separados. Los coeficientes estáticos individuales AIOE no son significativos al 5 %; la asociación negativa de desempleo en diferencias largas no presenta igual precisión en Within. Las diferencias entre escalas, periodos e índices se documentan sin seleccionar conclusiones por significancia. El bloque ML revela un límite de identificación que el aprendizaje flexible no corrige. Los escenarios expresan consecuencias condicionales de supuestos, no efectos causales ni pronósticos validados.

Persisten límites de cobertura ocupacional, independencia condicional, inferencia bajo imputación única y disponibilidad de un único año previo. Los códigos especiales de dos indicadores ampliados con elegibilidad no armonizada permanecen fuera de las regresiones publicadas. La reproducción del catálogo tecnológico parte del archivo recibido: los archivos originales de todos los cruces internacionales no están completos en este checkout, por lo que no se afirma una reconstrucción independiente de cada correspondencia original.

6.1. Procedimiento de reproducción

Los códigos y resultados permanecen organizados en sus carpetas de trabajo. La preparación del matching está separada de la publicación: compilar una tabla no vuelve a seleccionar donantes. El orden de actualización es preparación, índices, modelos, escenarios, verificaciones y documentos. Cada etapa puede ejecutarse por separado con `actualizar_todo.py`.

Etapa	Código y productos principales
Integración y panel	Preparación de integración ; productos en datos imputados
Índices y cobertura	Construcción común y auditoría de índices
Econometría clásica	Estimación comparable
Aprendizaje automático	Estimación ML
Escenarios	Microsimulación y escenarios por índices en la carpeta de proyecciones
Tablas de publicación	Tablas de publicación

Las huellas SHA-256 identifican versiones, no certifican validez científica. Los códigos fuente completos y las instrucciones se proporcionan en el repositorio público; las tablas se construyen leyendo los resultados vigentes y no mediante transcripción manual.

6.2. Código técnico de construcción de exposición

El siguiente bloque muestra la implementación común utilizada para construir y asignar los índices; las reglas de situación laboral y los faltantes son parte de la definición del análisis.

```
def cargar_indices():
    """Devuelve catálogo fijo455; mantiene originales y agrega12 columnas normalizadas."""
    d = pd.read_csv(FUENTE, dtype={'ciuo08':'string'})
    d['ciuo08'] = codigo_ocupacion(d.ciuo08)
    if d.ciuo08.isna().any() or d.ciuo08.duplicated().any():
        raise ValueError('Referencia ocupacional con códigos faltantes o duplicados')
```

```

for nombre, original in INDICADORES.items():
    s = pd.to_numeric(d[original], errors='coerce')
    n = s.notna().sum()
    if n < 2 or s.max() <= s.min():
        raise ValueError(f'Índice sin variación: {original}')
    d[f'{nombre}_pct'] = (s.rank(method='average')-1)/(n-1)
    d[f'{nombre}_mm'] = (s-s.min())/(s.max()-s.min())
for escala in ('pct', 'mm'):
    d[f'envolvente_{escala}'] = d[[f'{k}_{escala}' for k in
→ ('aioe', 'webb_ia', 'llm')]].max(axis=1, skipna=False)
return d

def ocupacion_analitica(df, variante='anterior'):
    """Actual para OCI=1; última ocupación OFICIO2 para DSI=1.

    Sensibilidad variante='buscada' usa OFICIO1 para DSI=1. No rellena
    ocupados sin código ni inactivos. Desempleo principal excluye personas
    sin experiencia/código previo disponible; no representa toda la fuerza laboral.
    """
    if variante not in ('anterior', 'buscada'):
        raise ValueError('variante debe ser anterior o buscada')
    col = 'OFICIO2_C8_geih' if variante == 'anterior' else 'OFICIO1_C8_geih'
    resultado = pd.Series(pd.NA, index=df.index, dtype='string')
    oc = df['OCI_geih'].eq(1); ds = df['DSI_geih'].eq(1)
    if (oc & ds).any():
        raise ValueError('Ocupados y desocupados simultáneos')
    resultado.loc[oc] = codigo_ocupacion(df.loc[oc, 'OFICIO2_C8_geih'])
    resultado.loc[ds] = codigo_ocupacion(df.loc[ds, col])
    return resultado

```

Referencias

- Bertrand, M., Duflo, E., & Mullainathan, S. (2004). How Much Should We Trust Differences-in-Differences Estimates? *The Quarterly Journal of Economics*, 119(1), 249-275. <https://doi.org/10.1162/003355304772839588>
- Borusyak, K., Hull, P., & Jaravel, X. (2022). Quasi-Experimental Shift-Share Designs. *The Review of Economic Studies*, 89(1), 181-213. <https://doi.org/10.1093/restud/rdab030>
- Callaway, B., Goodman-Bacon, A., & Sant'Anna, P. H. C. (2024). *Difference-in-Differences with a Continuous Treatment* (NBER Working Paper No. 32117). National Bureau of Economic Research. <https://doi.org/10.3386/w32117>
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *The Econometrics Journal*, 21(1), C1-C68. <https://doi.org/10.1111/ectj.12097>
- D'Orazio, M., Di Zio, M., & Scanu, M. (2006). *Statistical Matching: Theory and Practice*. Wiley. <https://doi.org/10.1002/0470023554>
- DANE. (2023). *Gran Encuesta Integrada de Hogares 2023: Diccionario de datos*. <https://microdatos.dane.gov.co/index.php/catalog/782/download/22612>
- DANE. (2025). *Índice de Precios al Consumidor: Octubre de 2025*. <https://www.dane.gov.co/files/operaciones/IPC/oct2025/graf-IPC-oct2025.html>
- Deaton, A. (1985). Panel Data from Time Series of Cross-Sections. *Journal of Econometrics*, 30(1-2), 109-126. [https://doi.org/10.1016/0304-4076\(85\)90134-4](https://doi.org/10.1016/0304-4076(85)90134-4)
- Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2024). GPTs are GPTs: Labor Market Impact Potential of LLMs. *Science*, 384(6702), 1306-1308. <https://doi.org/10.1126/science.adj0998>
- Felten, E. W., Raj, M., & Seamans, R. (2021). Occupational, Industry, and Geographic Exposure to Artificial Intelligence: A Novel Dataset and Its Potential Uses. *Strategic Management Journal*, 42(12), 2195-2217. <https://doi.org/10.1002/smj.3286>
- Goldsmith-Pinkham, P., Sorkin, I., & Swift, H. (2020). Bartik Instruments: What, When, Why, and How. *American Economic Review*, 110(8), 2586-2624. <https://doi.org/10.1257/aer.20181047>
- Nie, X., & Wager, S. (2021). Quasi-Oracle Estimation of Heterogeneous Treatment Effects. *Biometrika*, 108(2), 299-319. <https://doi.org/10.1093/biomet/asaa076>

- Rässler, S. (2002). *Statistical Matching: A Frequentist Theory, Practical Applications, and Alternative Bayesian Approaches* (Vol. 168). Springer-Verlag. <https://doi.org/10.1007/978-1-4613-0053-3>
- Ridder, G., & Moffitt, R. (2007). The Econometrics of Data Combination. En *Handbook of Econometrics* (Vol. 6, pp. 5469-5547). Elsevier. [https://doi.org/10.1016/S1573-4412\(07\)06075-X](https://doi.org/10.1016/S1573-4412(07)06075-X)
- Verbeek, M. (2008). Pseudo-Panels and Repeated Cross-Sections. En L. Mátyás & P. Sevestre (Eds.), *The Econometrics of Panel Data* (3rd ed., Vol. 46, pp. 369-383). Springer. https://doi.org/10.1007/978-3-540-75892-1_11
- Webb, M. (2020). *The Impact of Artificial Intelligence on the Labor Market* [Working Paper]. Stanford University. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3482150
- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data* (2nd ed.). MIT Press.